MTH303 Linear Statistical Models

第 4 章　广义线性模型：引论

Chapter 4: Generalized Linear Models — Introduction

详细讲义：每个推导的逐步参考

Detailed Lecture Notes: A Step-by-step Reference for Lecturing

对应课件 `MTH303_Chapter_4.pdf`（42 帧）

MTH303 Teaching Group · School of Mathematics and Physics · XJTLU

数值与符号核对脚本：`verify_edf.py`

这份讲义怎么用　How to use these notes

课件上只给结果的地方，这里把中间每一步都写出来；每个式子都可以直接在黑板上照抄，每个数字都可以当场核对。全篇按课件的 42 帧编号推进，每节标题后面标出对应帧号，方便上课时与幻灯片同步翻页。

三类标记

【步骤】（蓝框）是可以逐行照抄黑板的推导，编号与"第 1 步、第 2 步"对应，缺一步学生就跟不上。
【要点】（绿框）是结论以及结论成立的条件——条件往往比结论更容易被漏掉。
【易错】（红框）是讲课时最容易讲错、或学生最容易写错的地方，通常先给出错误写法，再给正确写法。
【板书】（灰框）给出建议写在黑板上的最小内容。

阅读顺序建议：第 1、2 节按帧顺序讲；第 3 节（指数族定义与均值方差定理）是本章的重心，定理的证明要能脱稿；第 4 节是八个特例的逐步分解，按同一套六步法写成，可以先讲正态与泊松，其余留作对照；第 5 节讲连接函数，第 6 节把模型设定收口。第 7 节是一份防错清单，上课前扫一遍最省事；第 8 节列出全篇的数值，便于当堂验算。

全章一条主线　The one-sentence story

把这句话写在黑板左上角，整节课不擦

线性模型同时钉死了两件事：**响应服从什么分布**，以及**均值怎样连到线性预测子**。广义线性模型只保留线性预测子，把前两件事分别交给一个指数族分布和一条连接函数。

四个环节，对应课件的四块：

1. **工具**（帧 3--15）：极大似然估计。参数怎么估出来。
2. **诊断**（帧 16--22）：线性模型哪里不够用。Cola--Temperature 的例子给出三个症状：预测值可以为负、方差随均值增长、尾部厚。
3. **框架**（帧 23--32）：指数分布族。一个分布属于指数族，就自动有了均值 $b'(\theta)$、方差 $a(\phi)b''(\theta)$ 与方差函数 $V(\mu)$。
4. **落地**（帧 33--41）：连接函数与四个具体模型，最后收成两行方程。

整章的算术核心只有一行：

$$\operatorname{Var}[Y] = a(\phi)\, V(\mu).$$

$a(\phi)$ 是尺度，$V(\mu)$ 是均值--方差关系。学生只要记住"方差不是常数，而是均值的函数"，本章的目的就达到了。

符号表　Notation

符号	含义	第一次出现
Y, y_i	响应变量、第 i 个观测	帧 6
$\boldsymbol{\theta}$	参数向量（第 1 节）；自然参数（第 3 节起）	帧 6 / 24
θ	自然参数（natural / canonical parameter），$\theta = \theta(\mu)$	帧 24
ϕ	离散度参数（dispersion parameter），$\phi > 0$	帧 24
$a(\phi)$	离散度的函数，常取 ϕ 或 1	帧 24
$b(\theta)$	累积量函数（cumulant function），决定均值与方差	帧 24
$c(y;\phi)$	只含数据与离散度、不含 θ 的项	帧 24
$\mu = \mathbb{E}[Y]$	均值，$= b'(\theta)$	帧 26
$V(\mu)$	方差函数（variance function），$V(\mu) = b''(\theta(\mu))$	帧 30
η	线性预测子（linear predictor），$\eta = \mathbf{x}^\top\boldsymbol{\beta}$	帧 18
$g(\cdot)$	连接函数（link function），$\eta = g(\mu)$	帧 19
$\mathbf{X}$, $\boldsymbol{\beta}$	设计矩阵（$n \times (p+1)$）、回归系数向量	帧 18
π	二项分布的比例参数；$\mu = n\pi$（计数版）	帧 33
λ	指数分布的率、伽马分布的率参数	帧 8 / 4.7
α, β	伽马分布的形状参数、Tutorial 6 的离散度参数（$\beta = 1/\alpha$）	4.7

两个符号陷阱，从第一节课就要立规矩

(i) 第 1 节的 $\boldsymbol{\theta}$ 是"参数向量"，第 3 节的 θ 是"自然参数"；两者不是同一个东西。讲义中第 1 节一律写 θ 表示二项/指数的比例或率，第 3 节起 θ 专指自然参数。
(ii) 指数分布 $f(y) = \theta e^{-\theta y}$ 里的 θ 是**率**（rate），均值是 $1/\theta$，不是 θ。第 14 帧的答案之所以是 $1/\bar{y}$ 而不是 $\bar{y}$，全部来自这一点。

42 帧速查　Frame map

帧	内容	本文位置
1–2	标题、目录	—
3–4	参数是固定的未知数；MLE 的想法	§1.1
5–6	独立同分布；似然与对数似然	§1.2
7–8	两个"写下来"例题：二项、指数	§1.3–1.4
9–12	最大化；对数单调性；两联图；两个例题的求解	§1.5–1.7
13–15	正态（两参数）；不能求导的情形（均匀分布）	§1.8–1.9
16–18	第 2 节标题页；三组件；GLM 放宽了什么	§2.1–2.2
19–22	Cola--Temperature 直觉例子（四帧）	§2.3
23	第 3 节标题页	—
24–25	指数族定义；参数化不唯一；自然指数族	§3.1–3.2
26–29	均值方差定理及其证明	§3.3–3.4
30–31	方差函数；方差函数表	§3.5
32	凹性；得分在均值处为零	§3.6
33	泊松分布的指数族验证	§4.5
34	二项分布的指数族验证	§4.4
35–36	连接函数定义；常见连接	§5.1–5.3
37–39	Gaussian / Poisson / Logistic / Probit 四个模型	§5.4
40–41	模型设定总结；GLM 定义与构造	§6
42	结束页	—

帧号即课件 PDF 的页码（页脚 $\mathrm{N}\ /\ 42$）。第 1 节覆盖帧 3--15，第 2 节覆盖 16--22，第 3 节覆盖 23--32，第 4 节把帧 33--34 的两个验证例题扩成八个特例，第 5 节覆盖 35--39，第 6 节覆盖 40--41。

Contents

这份讲义怎么用 1

全章一条主线 1

符号表 2

42 帧速查 3

1　极大似然估计 5

1.1　参数 . . . 5
1.2　似然与对数似然 . . . 5
1.3　例题一：二项分布（帧 7） . . . 5
1.4　例题二：指数分布（帧 8） . . . 6
1.5　最大化：为什么可以把似然换成对数似然 . . . 6
1.6　二项分布的极大似然估计 . . . 7
1.7　指数分布的极大似然估计 . . . 7
1.8　正态分布：两个参数联立 . . . 8

1.9　求导失效的例子：均匀分布 . . . 9
1.10 本节与第 5 章的接口 . . . 9

2　从线性模型到广义线性模型　9
2.1　线性模型的三个组件 . . . 10
2.2　GLM 放宽了什么 . . . 10
2.3　Cola--Temperature：为什么一条直线不行 . . . 10
2.4　记号与维数 . . . 11

3　指数分布族　11
3.1　定义 . . . 11
3.2　参数化不唯一与自然指数族 . . . 12
3.3　均值方差定理 . . . 13
3.4　定理的证明 . . . 13
3.5　方差函数 . . . 14
3.6　凹性与得分零点 . . . 14

4　指数族特例的逐步分解　15
4.1　特例一：正态（σ^2 已知） . . . 16
4.2　特例二：正态（μ 与 σ^2 都未知） . . . 16
4.3　特例三：伯努利 . . . 17
4.4　特例四：二项（计数版，帧 34） . . . 18
4.5　特例五：泊松（帧 33） . . . 18
4.6　特例六：指数 . . . 19
4.7　特例七：伽马 . . . 19
4.8　特例八：逆高斯 . . . 21
4.9　三个"不属于"的例子 . . . 21
4.10 总表与记忆法 . . . 22
4.11 四个高频错误 . . . 23

5　连接函数　23
5.1　定义与两条要求 . . . 24
5.2　典则连接 . . . 24
5.3　常见连接一览 . . . 25
5.4　四个具体模型 . . . 25
5.5　非典则连接：什么时候用、代价是什么 . . . 26

6　模型设定总结　26
6.1　两行方程与三个组件 . . . 27
6.2　三份完整设定示例 . . . 27
6.3　建模前的检查清单 . . . 27
6.4　与第 5、6 章的接口 . . . 28

7　讲课防错清单　28

8　数值核对表　29

A　附录：六步法一页纸　30

B　附录：从得分方程到 IRLS　31

1　极大似然估计　Maximum Likelihood Estimation（帧 3--15）

本章用极大似然估计（maximum likelihood estimation, MLE）把参数从数据里估出来。四个例题是后面全部内容的工具：二项与指数两题短，练的是"把似然写对"；正态题把两个参数联立的过程走一遍，并且第一次出现"极大似然估计可以有偏"；均匀分布题说明"求导置零"不是万能的，为第 5 章的数值优化埋下伏笔。

1.1　参数　Parameters（帧 3--4）

课件的定义是：参数是**固定的（但未知的）数**，它确定某一个具体的分布。这句话有两个作用：一是把参数与随机变量分开（频率派立场，参数没有分布）；二是把"估计"这件事说清楚——我们不是要找参数的概率分布，而是要在给定数据后指出哪个参数值最像样。

分布	记号	参数	备注
正态	$\mathrm{N}(\mu,\sigma^2)$	$\mu,\ \sigma^2$	两个都未知（第 2、3 章常设 σ^2 已知）
二项	$\mathrm{Binomial}(n,\pi)$	$n,\ \pi$	n 是试验次数，通常已知，**不算待估参数**
泊松	$\mathrm{Poisson}(\mu)$	μ	均值与方差是同一个数
指数	$\mathrm{Exp}(\theta)$	θ	这里的 θ 是率，均值是 $1/\theta$
伽马	$\mathrm{Gamma}(\alpha,\lambda)$	$\alpha,\ \lambda$	第 4.7 节会把其中一个当作离散度

讲这一帧时要说的一句

"二项分布里的 n 不是参数。"学生把 n 当参数估，后面第 11 帧的 $\hat\theta=\sum y_i/12$ 就会写成 $\sum y_i/4$——分母用观测数还是试验总数，是本章第一个、也是最常见的一个错误。

第 4 帧给出全章唯一的核心思想：**选出让已经观测到的数据"最可能出现"的参数值。**第 5 帧补上独立同分布（IID）假设，并说明它是"把 n 个观测的联合密度写成 n 个密度之积"的唯一依据。

1.2　似然与对数似然　Likelihood and log-likelihood（帧 6）

给定来自 $f(y;\boldsymbol\theta)$ 的样本 $y_1,\dots,y_n$，似然函数（likelihood function）是

$$L(\boldsymbol\theta;\mathbf{y})=\prod_{i=1}^{n} f(y_i;\boldsymbol\theta),\qquad \ell(\boldsymbol\theta;\mathbf{y})=\log L(\boldsymbol\theta;\mathbf{y})=\sum_{i=1}^{n}\log f(y_i;\boldsymbol\theta). \tag{1}$$

连乘来自独立性，连加来自对数的性质。这两个式子是本章后面每一个例题的起点，值得让学生当堂默写一遍。

三句必须说清楚的话

(1) 似然是**参数**的函数，数据是固定的。写 $L(\theta)$ 而不写 $L(y)$。
(2) 似然的值**不是概率**，可以大于 1（离散情形下它是一个概率的乘积，连续情形下是密度值），所以只有**相对大小**有意义。
(3) 取对数有两个好处：把连乘变成连加（好求导）；把指数族密度里的 exp 消掉（第 3 节全靠这一点）。

1.3　例题一：二项分布（帧 7）　Worked example 1: Binomial（只写不算）

设 $Y_i\sim\mathrm{Binomial}(3,\theta)$，观测到 $(y_1,y_2,y_3,y_4)=(1,3,2,2)$。这一帧只要求**写出**似然与对数似然，不求最大值；最大值留到第 11 帧。

第 1 步：写出单个观测的概率质量函数

$$\Pr(Y_i=y_i\mid\theta)=\binom{3}{y_i}\theta^{y_i}(1-\theta)^{3-y_i},\qquad y_i\in\{0,1,2,3\},\ 0\le\theta\le1.$$

第 2 步：独立性 ⇒ 连乘

$$L(\theta) = \prod_{i=1}^{4} \binom{3}{y_i} \theta^{y_i} (1-\theta)^{3-y_i}.$$

第 3 步：合并同类项（把 i 从指数上收下来）

$$L(\theta) = \Big[\prod_{i=1}^{4} \binom{3}{y_i}\Big] \theta^{\sum_i y_i} (1-\theta)^{12-\sum_i y_i} = 27\,\theta^{8}(1-\theta)^{4},$$

其中

$$\sum_i y_i = 1+3+2+2 = 8, \qquad 4 \times 3 = 12, \qquad \prod_i \binom{3}{y_i} = 3 \cdot 1 \cdot 3 \cdot 3 = 27.$$

第 4 步：取对数

$$\ell(\theta) = \log 27 + 8 \log \theta + 4 \log(1-\theta).$$

关键动作是**把组合系数留住**：它会进入第 3 节指数族里的 $c(y;\phi)$，但在第 11 帧对 θ 求导时自动消失。这个"现在留着、以后丢掉"的动作，正是后面泊松与二项两个验证例题里那个"只含数据的项"的预演。

1.4 例题二：指数分布（帧 8）　Worked example 2: Exponential（只写不算）

设 $Y_i \sim \mathrm{Exp}(\theta)$，$f_{Y_i}(y_i \mid \theta) = \theta e^{-\theta y_i}$，$y_i \geq 0$，$\theta > 0$；观测 $(1.23,\ 3.32,\ 1.98,\ 2.12)$。

第 1--4 步

$$L(\theta) = \prod_{i=1}^{4} \theta e^{-\theta y_i} = \theta^4 \exp\Big(-\theta \sum_i y_i\Big),$$

$$\ell(\theta) = 4 \log \theta - \theta \sum_i y_i = 4 \log \theta - 8.65\,\theta, \qquad \sum_i y_i = 1.23 + 3.32 + 1.98 + 2.12 = 8.65.$$

率还是均值：这一帧唯一但致命的陷阱

参数 θ 是**率**（rate），$\mathbb{E}[Y] = 1/\theta$。学生若把它读成均值，第 12 帧就会答 $\hat{\theta} = \bar{y} = 2.1625$，而正确答案是 $1/\bar{y} = 0.4624$。板书时把 θ 圈起来，旁边写 rate, not mean。

1.5 最大化：为什么可以把似然换成对数似然　Maximisation: why the log is allowed（帧 9--10）

第 9 帧给出定义 $\hat{\boldsymbol{\theta}} = \arg\max_{\boldsymbol{\theta}} L(\boldsymbol{\theta}; \mathbf{y})$，并指出 log 是单调函数，所以 arg max 不变。这句话值得用两分钟证明一遍，因为"位置相同、数值不同"是学生最容易混淆的地方。

证明：$\arg\max L = \arg\max \ell$

设 h 在 L 的值域上严格递增（log 在 $(0,\infty)$ 上如此）。对任意两个参数值 θ_1, θ_2：

$$L(\theta_1) > L(\theta_2) \iff h\big(L(\theta_1)\big) > h\big(L(\theta_2)\big) \iff \ell(\theta_1) > \ell(\theta_2).$$

所以 L 与 ℓ 给出的**大小顺序完全一致**，因而在同一处取最大：$\arg\max_\theta L(\theta) = \arg\max_\theta \ell(\theta)$。

两句不能说的话

错："对数似然的最大值等于似然的最大值。"
对：最大值所在的**位置**相同，最大值本身的**数值**不同。$L(\hat{\theta}) = 1.3 \times 10^{-2}$ 与 $\ell(\hat{\theta}) = -4.34$ 是两个不同的量。

第 10 帧的两联图值得花三分钟：离散情形画的是"在不同候选参数下，已观测数据的概率质量"，要挑最高的

柱子；连续情形画的是"不同参数对应的密度曲线"，要挑让观测点处密度乘积最大的那条曲线。两幅图讲的是同一件事——把参数当成横轴，把似然当成纵轴，找最高点。

1.6 二项分布的极大似然估计　Binomial MLE（帧 11）

第 1 步：抄回对数似然，丢掉不含 θ 的项

$$\ell(\theta) = \underbrace{\log 27}_{\text{常数}} + 8\log\theta + 4\log(1-\theta) \;\Longrightarrow\; \ell(\theta) = 8\log\theta + 4\log(1-\theta) + \text{const.}$$

第 2 步：求导，置零（得分方程）

$$\frac{\mathrm{d}\ell}{\mathrm{d}\theta} = \frac{8}{\theta} - \frac{4}{1-\theta} = 0.$$

第 3 步：解方程

$$8(1-\theta) = 4\theta \;\Longrightarrow\; 8 = 12\theta \;\Longrightarrow\; \hat\theta = \frac{8}{12} = \frac{2}{3} \approx 0.6667.$$

第 4 步：二阶导检验（考卷上不可省）

$$\frac{\mathrm{d}^2\ell}{\mathrm{d}\theta^2} = -\frac{8}{\theta^2} - \frac{4}{(1-\theta)^2} < 0 \quad \text{对所有 } 0<\theta<1, \qquad \left.\frac{\mathrm{d}^2\ell}{\mathrm{d}\theta^2}\right|_{\theta=2/3} = -54 < 0.$$

故 $\hat\theta = 2/3$ 是极大值点。

θ	0.4	0.5	2/3	0.8
ℓ（不含常数）	-9.3736	-8.3178	$\mathbf{-7.6382}$	-8.2229
$L(\theta)$	2.293×10^{-3}	6.592×10^{-3}	$\mathbf{1.3006\times10^{-2}}$	7.248×10^{-3}

一般结论与它的条件

若 $Y_i \sim \text{Binomial}(m,\theta)$ 独立，共 n 个观测，则

$$\hat\theta = \frac{\sum_{i=1}^{n} y_i}{nm} = \frac{\bar y}{m},$$

即"样本均值除以试验次数"。本题 $m=3$、$n=4$、$\sum y_i = 8$，故 $\hat\theta = 8/12$。

分母到底是 4 还是 12

4 是**观测个数**，12 是**试验总次数**。比例参数的估计量分母是后者。写错分母不会影响 $\hat\theta$ 的点估计（这里是 $8/12$ 而不是 $8/4$，那是另一个数），但会直接影响标准误——见第 8 节的数值核对。

1.7 指数分布的极大似然估计　Exponential MLE（帧 12）

三步

$$\begin{aligned}
&\ell(\theta) = 4\log\theta - 8.65\,\theta,\\
&\frac{\mathrm{d}\ell}{\mathrm{d}\theta} = \frac{4}{\theta} - 8.65 = 0 \quad\Longrightarrow\quad \hat\theta = \frac{4}{8.65} = \frac{1}{\bar y} = 0.462428,\quad \bar y = 2.1625,\\
&\frac{\mathrm{d}^2\ell}{\mathrm{d}\theta^2} = -\frac{4}{\theta^2} < 0 \quad\Longrightarrow\quad \text{极大值.}
\end{aligned}$$

θ	0.2500	0.4624	0.5000	1.0000	2.0000
$\ell(\theta)$	-7.7077	$\mathbf{-7.0851}$	-7.0976	-8.6500	-14.5274
$L(\theta)$	4.494×10^{-4}	$\mathbf{8.375\times10^{-4}}$	8.271×10^{-4}	1.751×10^{-4}	4.907×10^{-7}

注意 $\ell(0.5)=-7.0976$ 只比最大值低 0.012，肉眼在图上几乎看不出差别——这正好用来提醒学生：对数似然在最大值附近很平（曲率是 $-4/\theta^2$，在 $\hat\theta$ 处约 -18.7），所以估计量的标准误不会太小。

一般结论

指数分布率的极大似然估计是样本均值的倒数：$\hat\theta = 1/\bar y$。它与矩估计一致，但"两者相等"只是这一族分布的巧合，不是普遍规律。

1.8 正态分布：两个参数联立　Normal MLE with two parameters（帧 13--14）

设 $Y_i \sim \mathrm{N}(\theta_1, \theta_2)$ 独立，$\theta_2>0$ 是方差。这是本章唯一需要两个参数联立的推导，也是唯一能让学生看到"极大似然估计可以有偏"的地方，值得慢慢做。

第 1 步：写出对数似然（先不要展开常数）

$$L(\theta_1,\theta_2)=(2\pi\theta_2)^{-n/2}\exp\Big\{-\frac{1}{2\theta_2}\sum_{i=1}^{n}(y_i-\theta_1)^2\Big\},$$

$$\ell(\theta_1,\theta_2)=-\frac{n}{2}\log(2\pi)-\frac{n}{2}\log\theta_2-\frac{1}{2\theta_2}\sum_{i=1}^{n}(y_i-\theta_1)^2.$$

第 2--3 步：对 θ_1 求偏导并解出

$$\frac{\partial\ell}{\partial\theta_1}=\frac{1}{\theta_2}\sum_{i=1}^{n}(y_i-\theta_1)=0 \;\Longrightarrow\; \sum_i y_i=n\theta_1 \;\Longrightarrow\; \hat\theta_1=\bar y.$$

第 4--5 步：对 θ_2 求偏导，代入 $\hat\theta_1$

$$\frac{\partial\ell}{\partial\theta_2}=-\frac{n}{2\theta_2}+\frac{1}{2\theta_2^2}\sum_{i=1}^{n}(y_i-\theta_1)^2=0 \;\Longrightarrow\; \hat\theta_2=\frac{1}{n}\sum_{i=1}^{n}(y_i-\hat\theta_1)^2=\frac{1}{n}\sum_{i=1}^{n}(y_i-\bar y)^2.$$

注意分母是 n，不是 $n-1$。

第 6 步：二阶条件（海森矩阵负定）

$$\frac{\partial^2\ell}{\partial\theta_1^2}=-\frac{n}{\theta_2}<0,\qquad \frac{\partial^2\ell}{\partial\theta_1\partial\theta_2}=-\frac{1}{\theta_2^2}\sum_i(y_i-\theta_1)=0 \quad\text{（在 MLE 处）},$$

$$\frac{\partial^2\ell}{\partial\theta_2^2}=\frac{n}{2\theta_2^2}-\frac{1}{\theta_2^3}\sum_i(y_i-\theta_1)^2 \overset{\text{MLE}}{=} \frac{n}{2\theta_2^2}-\frac{n}{\theta_2^2}=-\frac{n}{2\theta_2^2}<0.$$

两个对角元都为负、交叉项为零，故海森矩阵负定，是极大值。

数据 $(1.2, 2.4, 0.9, 3.1, 2.6)$，$n=5$	$\bar y$	$\hat\theta_2$	ℓ
在 MLE 处	2.0400	0.7144	-6.2539
在 $(1.9,\ 0.5)$	—	—	-6.5318
在 $(2.5,\ 1.5)$	—	—	-7.1517

海森矩阵在 MLE 处的两个对角元是 -6.9989 与 -4.8984，与上式的 $n/\hat\theta_2$、$n/(2\hat\theta_2^2)$ 一致。

有偏性：为什么分母是 n 而不是 $n-1$

$$\frac{1}{\sigma^2}\sum_{i=1}^{n}(Y_i-\bar{Y})^2 \sim \chi^2_{n-1} \quad\Longrightarrow\quad \mathbb{E}\Big[\sum_i (Y_i-\bar{Y})^2\Big] = (n-1)\sigma^2 \quad\Longrightarrow\quad \mathbb{E}[\hat{\theta}_2] = \frac{n-1}{n}\sigma^2 < \sigma^2.$$

所以 $\hat{\theta}_2$ 是**有偏**的（偏小），无偏版本才除以 $n-1$。极大似然不保证无偏；无偏是另一条判据。第 6 章用自由度而不是样本量去除偏差，根子在这里。

上例中 $\hat{\theta}_2 = 0.7144$、$s^2 = 0.8930$，比值 $0.7144/0.8930 = 0.8 = (n-1)/n$，可以当堂验证"偏差因子"。

与最小二乘的关系（第 2、3 章的接口）

θ_1 只通过残差平方和 $\mathrm{RSS} = \sum(y_i-\theta_1)^2$ 进入对数似然，所以关于 θ_1 最大化 ℓ 等价于关于 θ_1 最小化 RSS——正态假设下极大似然与最小二乘给出同一个 $\hat{\theta}_1 = \bar{y}$（回归情形下是 $\hat{\boldsymbol{\beta}} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}$）。这正是第 2、3 章的结果能在 GLM 框架下被继承的原因。

1.9　求导失效的例子：均匀分布　When calculus fails: the Uniform（帧 15）

设 $Y_1,\dots,Y_n$ 独立同分布于 $(0,\theta)$ 上的均匀分布，$y_{(n)} = \max_i y_i$。则

$$L(\theta) = \prod_{i=1}^{n}\frac{1}{\theta}\mathbf{1}\{0 < y_i < \theta\} = \theta^{-n}\,\mathbf{1}\{\theta \ge y_{(n)}\}.$$

两步看完，不用求导

(i) 当 $\theta < y_{(n)}$ 时，至少有一个观测落在 $(0,\theta)$ 之外，$L(\theta) = 0$。
(ii) 当 $\theta \ge y_{(n)}$ 时，$L(\theta) = \theta^{-n}$ 关于 θ 严格递减，故在区间的左端点取最大：

$$\hat{\theta} = y_{(n)}.$$

而 $\ell(\theta) = -n\log\theta$ 的导数是 $-n/\theta < 0$，**处处不为零**——"求导置零"给不出任何解。

这题的教学价值

它同时说明三件事：(1) 最大值可以在**边界**上；(2) 支撑集依赖参数时，通常的求导法则不适用；(3) 极大似然估计不一定有解析解。第 15 帧的第二句话"一般情况下 $\hat{\theta}$ 没有解析形式，需要数值优化，唯一的例外是线性回归"就是从这里通向第 5 章的。

1.10　本节与第 5 章的接口　Bridge to Chapter 5

把本节的四个例题放在一起看，有一个共同结构：得分方程（score equation）$\partial\ell/\partial\theta = 0$ 是估计量的定义，而它一般是非线性方程。二项、指数、正态三题能解出闭式解，是因为它们的得分方程恰好是线性或可分参的；一旦换成 logistic 回归或带连接的泊松回归，得分方程就变成

$$\sum_{i=1}^{n}\frac{(y_i-\mu_i)\,x_{ij}}{a(\phi)\,V(\mu_i)} = 0, \qquad j = 0,1,\dots,p,$$

只能用 Newton--Raphson、Fisher scoring 或迭代重加权最小二乘（IRLS）迭代求解。第 5 章的主题就是这个方程组怎么解。

2　从线性模型到广义线性模型　From the Linear Model to the GLM（帧 16--22）

第 1 节备好了工具（极大似然），第 2 节说明为什么需要换一个框架。课件的处理方式很克制：不先抛定义，而是先给一个真实数据（Cola--Temperature），让线性回归当场出丑，再回头指出线性模型的三个组件里哪两个必须放宽。

2.1 线性模型的三个组件　The three components of a linear model（帧 17）

组件	线性模型（LRM）	广义线性模型（GLM）
随机成分 Random	响应连续、正态：$y \sim \mathrm{N}(\mu, \sigma^2)$， $\boldsymbol{\mu} = \mathbb{E}[\mathbf{y}]$	响应服从某个指数族分布 $y \sim \mathrm{EDF}(\theta, \phi)$
系统成分 Systematic	自变量的线性组合 $\beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p = \mathbf{X}\boldsymbol{\beta}$	完全相同，**不变** $\eta = \mathbf{X}\boldsymbol{\beta}$
连接 Link	$\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$ （恒等）	$g(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta}$

这一帧要让学生说出口的一句话

"**系统成分不变，放宽的是另外两个。**"线性预测子 $\eta = \mathbf{X}\beta$ 原封不动；随机成分从正态扩到指数族，连接从恒等扩到一般的 g。整门课后面的一切，都是在这句话之上做记账。

2.2 GLM 放宽了什么　What a GLM relaxes（帧 18）

两处推广，写成两行

(1) 随机成分： $\mathbf{y} \sim$ 某个指数族分布，$\boldsymbol{\mu} = \mathbb{E}[\mathbf{y}]$；
(2) 连接： $g(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta}$，其中 g 称为连接函数（link function），且 $\boldsymbol{\mu} = g^{-1}(\mathbf{X}\boldsymbol{\beta})$。

注意课件在这里还没有给出指数族的定义（定义在第 24 帧）。这是有意的：先用"某个指数族分布"占位，等 Cola 的例子把动机讲透，再回头补定义。讲课顺序不要调换，否则学生会觉得指数族是从天上掉下来的。

2.3 Cola--Temperature：为什么一条直线不行　Cola--Temperature: why a straight line fails（帧 19--22）

数据：某高校校园内可口可乐的销量（Cola，响应）与气温（Temperature，自变量）。响应变量有三个特征：**只取正值**、**厚尾**（少数高温天销量特别大）、**方差随均值增长**。

第 19--20 帧：直接用简单线性回归，会坏在哪

拟合 $\mathrm{Cola}_i = \beta_0 + \beta_1\,\mathrm{Temperature}_i + \varepsilon_i$ 之后：
(i) 拟合很差，R^2 低；
(ii) 预测值可以为**负**——课件给出的例子是：气温低于 10 度时，模型预测销量为负；
(iii) 同方差假设不成立：高温端的散点离散程度远大于低温端。

三条症状对应三个数学问题：(ii) 是**均值空间**与**实数直线**不匹配，需要连接函数；(iii) 是**方差不是常数**，需要方差函数 $V(\mu)$；(i) 是分布选错（正态、对称、方差恒定），需要换随机成分。

第 21--22 帧：课件的做法——对响应取对数

$$\log(\mathrm{Cola}_i) = \beta_0 + \beta_1\,\mathrm{Temperature}_i + \varepsilon_i, \qquad \varepsilon_i \sim \mathrm{N}(0, \sigma^2),$$

再对 $\log(\mathrm{Cola})$ 做简单线性回归，拟合明显改善（课件用调整 R^2 比较）。

本章最重要的一处区分：log 变换 $\neq$ log 连接

(a) 对响应取对数（第 21 帧做的）改变的是**数据**：模型变成 $\log Y = \mathbf{x}^\top\boldsymbol{\beta} + \varepsilon$，等价于 Y 服从**对数正态**分布，于是

$$\mathbb{E}[Y] = \exp\left(\mathbf{x}^\top\boldsymbol{\beta} + \frac{\sigma^2}{2}\right), \qquad \mathrm{Var}[Y] = e^{2\mathbf{x}^\top\boldsymbol{\beta}+\sigma^2}\left(e^{\sigma^2}-1\right).$$

(b) 用对数连接（第 38 帧泊松回归做的）不改变数据：Y 仍服从泊松分布，只是均值与线性预测子的关系变成

$$\log\mu = \mathbf{x}^\top\boldsymbol{\beta} \iff \mu = \exp(\mathbf{x}^\top\boldsymbol{\beta}), \qquad \mathrm{Var}[Y] = \mu = \exp(\mathbf{x}^\top\boldsymbol{\beta}).$$

两者都写成"log 线性"，但**似然不同、方差函数不同、系数解释不同**：(a) 的 β_1 是"温度每升 1 度，对数销量平均增加 β_1"；(b) 的 β_1 是"温度每升 1 度，期望销量乘以 e^{β_1}"。考试里把两者混为一谈是常见失分点。

回变换的偏差：一个必须提醒的技术点

在 (a) 中，若直接用 $\exp(\mathbf{x}^\top\hat{\boldsymbol{\beta}})$ 预测 $\mathbb{E}[Y]$，会**系统性偏低**，因为 $\mathbb{E}[e^{\varepsilon}] = e^{\sigma^2/2} > 1$。修正常用两种：乘 $e^{\hat\sigma^2/2}$（正态假设下精确），或用 Duan 的 smearing 估计 $\frac{1}{n}\sum_i e^{\hat\varepsilon_i}$（不依赖正态假设）。这也是"变换响应"与"换连接"的实质差别之一。

课件第 22 帧只做到"变换后拟合改善"就停住，把"为什么变换有效、它的代价是什么"留给了第 3 节。讲课时用一句话过渡：变换是一个**临时的补丁**，GLM 给的是**结构性的解**——保持 Y 的分布不变，只改均值与线性预测子的连接方式。

2.4 记号与维数　Notation and dimensions（帧 18、41 用）

第 i 个观测的线性预测子（linear predictor）是

$$\eta_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} = \mathbf{x}_i^\top\boldsymbol{\beta}, \qquad \mathbf{X} = \begin{pmatrix}\mathbf{x}_1^\top \\ \vdots \\ \mathbf{x}_n^\top\end{pmatrix} \in \mathbb{R}^{n\times(p+1)}, \quad \boldsymbol{\beta}\in\mathbb{R}^{p+1}.$$

$\mathbf{X}$ 称为设计矩阵（model matrix / design matrix），第一列通常全为 1（截距）。GLM 的两行方程是

$$\mathbf{y} = \boldsymbol{\mu} + \boldsymbol{\varepsilon}, \qquad g(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta},$$

第一行说响应围绕均值波动（$\mathbb{E}[\varepsilon]=\mathbf{0}$），第二行说均值经过 g 之后是线性的。

维数上的两个常见错误

(i) 把 $\mathbf{X}$ 写成 $n\times p$：漏掉截距列（应为 $p+1$ 列）。
(ii) 把 $\eta = g(\boldsymbol{\mu})$ 与 $\boldsymbol{\mu} = g(\mathbf{X}\boldsymbol{\beta})$ 混用：正确的是 $\boldsymbol{\mu} = g^{-1}(\mathbf{X}\boldsymbol{\beta})$，而 $\eta = \mathbf{X}\boldsymbol{\beta} = g(\boldsymbol{\mu})$。

3 指数分布族　The Exponential Family of Distributions（帧 23--32）

这一节是全章的重心，也是唯一一处"定义 + 定理 + 证明"三件套齐全的地方。讲法建议：先把定义里的五个符号逐个说清楚（第 24 帧），再用正态的两种写法说明参数化不唯一（第 25 帧），然后证明均值方差定理（第 26--29 帧），最后落到方差函数与两个性质（第 30--32 帧）。定理的证明要能脱稿讲，因为它是第 5 章 Fisher 信息的原型。

3.1 定义　Definition（帧 24）

$$f(y;\theta,\phi) = \exp\left\{\frac{y\theta - b(\theta)}{a(\phi)} + c(y;\phi)\right\}, \qquad \theta\in\Theta\subseteq\mathbb{R}, \quad \phi>0. \tag{2}$$

符号	作用与约束
θ	自然参数（natural / canonical parameter）。它是均值的函数：$\theta = \theta(\mu)$。
ϕ	离散度参数（dispersion parameter），$\phi > 0$。
$a(\phi)$	离散度的函数，ϕ 只通过它进入似然。常取 $a(\phi) = \phi$ 或 $a(\phi) = 1$。
$b(\theta)$	累积量函数（cumulant function），**同一个 b 同时决定均值与方差。**
$c(y;\phi)$	只含数据与离散度、**不含** θ 的项；离散分布里常是组合数/阶乘，连续分布里常含 $\log y$。

定义里三个容易被忽略的约束

(1) c 不能含 θ。 否则"参数"与"数据"混在一起，$b'(\theta) = \mu$ 的推导立刻失效。
(2) 支撑集（support）不能依赖 θ。 均匀分布 $U(0,\theta)$ 就是在这里出局的：它的指示函数依赖 θ。
(3) θ 的取值范围 Θ 是分布自身的自然参数空间，不一定是整个 $\mathbb{R}$：伽马与逆高斯要求 $\theta < 0$。课件写 $\theta \in \mathbb{R}$ 是简化说法，讲课时补一句"对具体分布是 $\mathbb{R}$ 的某个子集"。

为什么要写成这个形式？因为这个形式把"数据"与"参数"分开了：$y\theta$ 是数据乘参数，$b(\theta)$ 只含参数，$c(y;\phi)$ 只含数据。分开之后，才能对 θ 求导并把导数变成期望——这正是下一小节定理的证明思路。

3.2 参数化不唯一与自然指数族　Non-uniqueness and the natural exponential family（帧 25）

课件说"参数的选择不唯一"，这句话最好用一个具体例子讲，否则学生不知道"不唯一"到什么程度。用正态分布，两种都合法：

同一个正态分布的两种指数族写法

写法 A（GLM 采用）： $\theta = \mu$，$\phi = \sigma^2$，$a(\phi) = \phi$，$b(\theta) = \theta^2/2$

$$f = \exp\left\{\frac{y\theta - \theta^2/2}{\phi} - \frac{y^2}{2\phi} - \frac{1}{2}\log(2\pi\phi)\right\}.$$

写法 B： $\theta = \dfrac{\mu}{\sigma^2}$，$\phi = \sigma^2$，$a(\phi) = 1$，$b(\theta) = \dfrac{\sigma^2\theta^2}{2}$

$$f = \exp\left\{y\theta - \frac{\sigma^2\theta^2}{2} - \frac{y^2}{2\sigma^2} - \frac{1}{2}\log(2\pi\sigma^2)\right\}.$$

两边都还原出同一个密度，且都满足 $b'(\theta) = \mu$。差别在方差函数：写法 A 给出 $V(\mu) = 1$，写法 B 给出 $V(\mu) = \sigma^2$。

为什么 GLM 只用写法 A

GLM 要求 $V(\mu)$ **只依赖 μ、不依赖 ϕ**——否则"分布决定方差函数"这句话就没有意义，第 5 章的 IRLS 权重也会依赖未知的离散度而无法统一定义。写法 A 把 ϕ 全部塞进 $a(\phi)$，于是 $b''(\theta(\mu))$ 与 ϕ 无关。所以"参数化不唯一"不等于"随便选"：**把离散度全部推到 $a(\phi)$ 里的那种写法才是标准写法。**

两个常用的特例：**(i) 自然指数族**（natural exponential family）：$a(\phi) = 1$、$c(y;\phi) = c(y)$，于是

$$f(y;\theta) = \exp\{c(y)\}\exp\{y\theta - b(\theta)\}.$$

(ii) 一般的 k 参数指数族：

$$f(y;\boldsymbol{\theta}) = \exp\left\{\sum_{i=1}^{k}\theta_i t_i(y) - b(\boldsymbol{\theta}) + c(y)\right\},$$

其中 $t_i(y)$ 是充分统计量。第 4.2 节的两参数正态就是 $k = 2$ 的情形；课件 (1) 式的形式是"$k = 1$ 再加一个离散度"的特例。

3.3 均值方差定理　The mean--variance theorem（帧 26）

定理

若 Y 服从 (2) 的指数族分布，则

$$\boxed{\mu = \mathbb{E}[Y] = b'(\theta), \qquad \operatorname{Var}[Y] = a(\phi)\, b''(\theta)}$$

其中 b'、b'' 是对 θ 的一阶、二阶导数。

这个定理的重要性在于：**均值和方差来自同一个函数** b。一旦分布选定，b 就定了，均值与方差如何随 θ 变化就同时定了——方差不是自由的参数，它是均值的函数（差一个尺度 $a(\phi)$）。

3.4 定理的证明　Proof of the theorem（帧 27--29）

第 1 步：写出单个观测的对数似然及其导数

$$\ell(\theta; y) = \log f(y; \theta, \phi) = \frac{y\theta - b(\theta)}{a(\phi)} + c(y; \phi),$$

$$\frac{\partial \ell}{\partial \theta} = \frac{y - b'(\theta)}{a(\phi)}, \qquad \frac{\partial^2 \ell}{\partial \theta^2} = -\frac{b''(\theta)}{a(\phi)}.$$

第 2 步：用"密度积分为 1"这条恒等式

对任意 $\theta \in \Theta$，

$$\int f(y; \theta, \phi)\, \mathrm{d}y = 1 \qquad \Big(\text{离散情形为 } \sum_y f(y; \theta, \phi) = 1\Big).$$

两边对 θ 求导。假定可以在积分号下求导（见下面的正则性条件），并用 $\dfrac{\partial f}{\partial \theta} = f \cdot \dfrac{\partial \ell}{\partial \theta}$：

$$0 = \int \frac{\partial f}{\partial \theta}\, \mathrm{d}y = \int f\, \frac{\partial \ell}{\partial \theta}\, \mathrm{d}y = \mathbb{E}\Big[\frac{\partial \ell}{\partial \theta}\Big].$$

第 3 步：代入导数，得到均值

$$0 = \mathbb{E}\Big[\frac{Y - b'(\theta)}{a(\phi)}\Big] = \frac{\mathbb{E}[Y] - b'(\theta)}{a(\phi)} \quad \Longrightarrow \quad \boxed{\mathbb{E}[Y] = b'(\theta)}.$$

第 4 步：再求一次导，得到方差

对 $\displaystyle\int f\, \frac{\partial \ell}{\partial \theta}\, \mathrm{d}y = 0$ 再关于 θ 求导，注意 $\dfrac{\partial}{\partial \theta}\Big(f \dfrac{\partial \ell}{\partial \theta}\Big) = f \dfrac{\partial^2 \ell}{\partial \theta^2} + f\Big(\dfrac{\partial \ell}{\partial \theta}\Big)^2$：

$$0 = \mathbb{E}\Big[\frac{\partial^2 \ell}{\partial \theta^2}\Big] + \mathbb{E}\Big[\Big(\frac{\partial \ell}{\partial \theta}\Big)^2\Big].$$

由 $\mathbb{E}[\partial \ell / \partial \theta] = 0$，第二项就是 $\operatorname{Var}\big(\partial \ell / \partial \theta\big)$，于是

$$\mathbb{E}\Big[\frac{\partial^2 \ell}{\partial \theta^2}\Big] = -\operatorname{Var}\Big(\frac{\partial \ell}{\partial \theta}\Big).$$

第 5 步：把两个导数代回去

$$-\frac{b''(\theta)}{a(\phi)} = -\operatorname{Var}\Big(\frac{Y - b'(\theta)}{a(\phi)}\Big) = -\frac{\operatorname{Var}[Y]}{a(\phi)^2} \quad \Longrightarrow \quad \boxed{\operatorname{Var}[Y] = a(\phi)\, b''(\theta)}.$$

正则性条件（课件用一句话带过，讲课时要交代）

(1) Y 的支撑集不能依赖 θ（否则积分限随 θ 变，求导要加边界项）；
(2) $\partial f/\partial\theta$ 存在，且积分与求导可以交换（被积函数被可积函数控制）；
(3) θ 在参数空间的内点。 这三条在指数族的自然参数空间内部对常见分布都成立；均匀分布违反第 (1) 条，所以它不在指数族里（见第 4.9 节）。

证明的两个"副产品"，第 5 章要直接用

(i) $\mathbb{E}[\partial\ell/\partial\theta]=0$：得分函数（score）的均值为零，这是所有极大似然理论的第一条恒等式。
(ii) $\mathbb{E}[\partial^2\ell/\partial\theta^2]=-\mathbb{E}[(\partial\ell/\partial\theta)^2]$：观测信息与期望信息相等的原型。单个观测的 Fisher 信息是

$$\mathcal{I}(\theta)=-\mathbb{E}\Big[\frac{\partial^2\ell}{\partial\theta^2}\Big]=\frac{b''(\theta)}{a(\phi)}=\frac{V(\mu)}{a(\phi)}.$$

3.5 方差函数　The variance function（帧 30--31）

从 b'' 到 $V(\mu)$：三步

(1) $\mu=b'(\theta)$ 把 θ 映成 μ；
(2) 因为 $b''(\theta)>0$，b' 严格递增，故可逆，记 $\theta=\theta(\mu)=(b')^{-1}(\mu)$；
(3) 定义**方差函数**（variance function）

$$V(\mu):=b''\big(\theta(\mu)\big),\qquad \text{于是}\qquad \mathrm{Var}[Y]=a(\phi)\,V(\mu).$$

响应分布	正态	伯努利	泊松	伽马	逆高斯
$V(\mu)$	1	$\mu(1-\mu)$	μ	μ^2	μ^3

把这五个方差函数与 $a(\phi)$ 放在一起看，就有本章最值钱的一句话：

$$\mathrm{Var}[Y]=a(\phi)\,V(\mu)\quad\Longrightarrow\quad\begin{cases}a(\phi)\text{ 是尺度（scale），}\\ V(\mu)\text{ 是均值--方差关系（mean--variance relationship）．}\end{cases}$$

三条由方差函数直接读出的结论

(1) 异方差是结构性的（heteroskedasticity is structural）：泊松的方差等于均值，μ 一变方差就变，**不可能**是常数；所以对计数数据用普通最小二乘，标准误一定是错的。
(2) 加权最小二乘的权重来自 V：第 5 章 IRLS 的权重是 $w_i\propto 1/\big(a(\phi)V(\mu_i)\big)$，方差大的观测权重小。
(3) 分布只需要通过 V 与 g 进入拟合：给定 V 与 g，算法完全一样——这正是 GLM 能"一套算法拟合所有分布"的原因。

3.6 凹性与得分零点　Concavity and the zero score（帧 32）

两个性质，各一行

(1) 关于 θ 严格凹：

$$\frac{\partial^2\ell}{\partial\theta^2}=-\frac{b''(\theta)}{a(\phi)}<0\qquad(\text{因 } b''>0,\ a(\phi)>0),$$

故对数似然在 θ 上严格凹，最大值唯一，数值优化稳定。
(2) 单观测的得分在"均值等于数据"处为零：

$$\frac{\partial\ell}{\partial\theta}=\frac{y-b'(\theta)}{a(\phi)}=0\iff b'(\theta)=y\iff\mu=y.$$

第 (2) 条看起来平淡，其实是 IRLS 的种子：若只有一个观测且没有回归结构，极大似然估计就是"令拟合均值等于观测值"。有回归结构时，这句话变成"令加权残差与每个自变量正交"，即 $\sum_i x_{ij}(y_i-\mu_i)/\big(a(\phi)V(\mu_i)\big)=0$，$j=0,\dots,p$。

板书规划（第 3 节）

左面板（整节课不擦）：

$$f(y;\theta,\phi)=\exp\left\{\frac{y\theta-b(\theta)}{a(\phi)}+c(y;\phi)\right\},\qquad \mu=b'(\theta),\quad \mathrm{Var}[Y]=a(\phi)b''(\theta),$$

再加一行 $\mathrm{Var}[Y]=a(\phi)V(\mu)$ 与方差函数表。右面板做证明的五个步骤，并随时回到左面板核对。

4 指数族特例的逐步分解　Decomposing Each Special Case（帧 33--35）

这一节是全篇的核心：把课件第 33、34 帧的两个验证例题（泊松、二项）扩成八个特例，每一个都用**同一套六步法**分解。讲课时的价值在于"可复制"：学生学会一套动作，就能自己处理伽马、逆高斯，乃至习题课上那些"看着陌生、其实是伽马"的密度。

课件的顺序是先泊松、后二项；本节的顺序按"由易到难、由连续到离散"重排为：正态（方差已知）→ 两参数正态 → 伯努利 → 二项 → 泊松 → 指数 → 伽马 → 逆高斯。最后三个"不属于"的反例（均匀、韦布尔）收尾。

六步法　The six-step procedure

六个动作：把任意密度写成指数族形式

第 1 步：写密度。 写出 $f(y;\cdot)$（pdf 或 pmf）以及**支撑集**；先确认支撑不依赖参数。
第 2 步：取对数。 写出 $\log f$，常数先不要丢。
第 3 步：归并数据项。 把所有含 y 的项整理成

$$\log f=\underbrace{y\cdot\kappa(\text{参数})}_{\text{数据}\times\text{自然参数}}+\underbrace{A(y)}_{\text{只含数据}}+\underbrace{B(\text{参数})}_{\text{只含参数}}+\text{常数}.$$

第 4 步：读出 θ 与 b。 系数 κ 就是 θ；由 $B(\text{参数})=-b(\theta)/a(\phi)$ 反解 $b(\theta)$。
第 5 步：读出 $a(\phi)$ 与 $c(y;\phi)$。 $a(\phi)$ 由 B 的分母决定（常见是 ϕ 或 1）；剩下的全部归入 $c(y;\phi)$，并检查它**不含** θ。
第 6 步：三项核对。 $b'(\theta)=\mu$；$a(\phi)b''(\theta)=\mathrm{Var}[Y]$；$b''>0$。再由 $\mu=b'(\theta)$ 反解 $\theta=\theta(\mu)$，得 $V(\mu)=b''(\theta(\mu))$ 与典则连接 $g(\mu)=\theta(\mu)$。

第 3 步是全部技巧所在

学生的困难几乎都集中在第 3 步："怎么知道把哪一项当 θ？" 答案是：**看 y 的系数。**密度里 y 一定以 $y\cdot(\text{某东西})$ 的形式出现（离散型还要加上 c 里的组合数），那个"某东西"就是 θ。如果 y 出现在非线性位置（如 y^k 且 k 未知、或 $\log y$ 乘以一个含参数的量），先把它挪到 $A(y)$ 或 $c(y;\phi)$ 里；挪不动，它就不在这个模板里（见 4.9）。

第 6 步不可省

它是唯一能查出"b 或 ϕ 分配错"的检查。$b'(\theta)$ 必须等于已知的均值，$a(\phi)b''(\theta)$ 必须等于已知的方差——两者都对上，分解才算完成。考试里少写这一步，通常会丢掉过程分；讲课里少做这一步，学生会把"凑出来的 b"当成正确答案。

4.1 特例一：正态（σ^2 已知）　Normal with known variance

六步分解

【1】 $f(y;\mu,\sigma^2)=\dfrac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\dfrac{(y-\mu)^2}{2\sigma^2}\right\}$，支撑 $y\in\mathbb{R}$，与参数无关。

【2】 $\log f=-\dfrac{(y-\mu)^2}{2\sigma^2}-\dfrac{1}{2}\log(2\pi\sigma^2)$。

【3】 把分子展开：$(y-\mu)^2=y^2-2y\mu+\mu^2$，代回并按"$y$ 的一次项 / 只含 y / 只含参数"重排：

$$\log f=\frac{y\mu-\mu^2/2}{\sigma^2}-\frac{y^2}{2\sigma^2}-\frac{1}{2}\log(2\pi\sigma^2).$$

【4】 y 的系数是 μ/σ^2，而分母里还有一个 σ^2；把 σ^2 提到分母外，就得到 $\theta=\mu$、$b(\theta)=\theta^2/2$、$a(\phi)=\phi=\sigma^2$。

【5】 $c(y;\phi)=-\dfrac{y^2}{2\phi}-\dfrac{1}{2}\log(2\pi\phi)$，不含 θ。

【6】 $b'(\theta)=\theta=\mu$；$b''(\theta)=1$；$\mathrm{Var}[Y]=a(\phi)b''(\theta)=\sigma^2$。

θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	典则连接
μ	σ^2	ϕ	$\theta^2/2$	1	$g(\mu)=\mu$（恒等）

抽检：$\mu=3$，$\sigma^2=4$ 时 $b'(3)=3$，$a(\phi)b''=4\times1=4=\mathrm{Var}[Y]$。

两个易错点

(i) 不要把 $-\dfrac{y^2}{2\sigma^2}$ 塞进 $b(\theta)$：它含 y，只能进 $c(y;\phi)$。

(ii) 若把 σ^2 也当成待估参数（变成下一小节的两参数情形），θ 与 b 都会变——见下一个特例。

4.2 特例二：正态（μ 与 σ^2 都未知）　Normal with both parameters unknown

这是唯一一个"离散度也未知"的连续例子，也是学生最容易被"θ 是标量"这一说法卡住的地方。正确做法：把它看成**两参数指数族**，自然参数是一个向量。

六步分解（按两参数模板）

【1】 $f(y;\mu,\sigma^2)=\dfrac{1}{\sqrt{2\pi\sigma^2}}\exp\left\{-\dfrac{(y-\mu)^2}{2\sigma^2}\right\}$。

【2】 $\log f=-\dfrac{1}{2}\log(2\pi)-\dfrac{1}{2}\log\sigma^2-\dfrac{(y-\mu)^2}{2\sigma^2}$。

【3】 令自然参数

$$\eta_1=\frac{\mu}{\sigma^2},\qquad \eta_2=-\frac{1}{2\sigma^2}\ (<0),$$

则 $\dfrac{1}{2\sigma^2}=-\eta_2$，$\mu=-\dfrac{\eta_1}{2\eta_2}$，$\sigma^2=-\dfrac{1}{2\eta_2}$。代入并归并：

$$\log f=\eta_1\,y+\eta_2\,y^2-\frac{\eta_1^2}{4\eta_2}-\frac{1}{2}\log(-2\eta_2)\ -\ \frac{1}{2}\log(2\pi).$$

【4】 对照 $f=\exp\{\eta_1 t_1(y)+\eta_2 t_2(y)-b(\boldsymbol{\theta})+c(y)\}$，其中 $t_1(y)=y$、$t_2(y)=y^2$，得

$$b(\boldsymbol{\theta})=-\frac{\eta_1^2}{4\eta_2}-\frac{1}{2}\log(-2\eta_2),\qquad c(y)=-\frac{1}{2}\log(2\pi).$$

【5】 这里**没有离散度参数**：两个参数都进了自然参数，$a(\phi)\equiv 1$。

【6】 对 η_1、η_2 分别求偏导：

$$\frac{\partial b}{\partial\eta_1}=-\frac{\eta_1}{2\eta_2}=\mu,\qquad \frac{\partial b}{\partial\eta_2}=\frac{\eta_1^2}{4\eta_2^2}-\frac{1}{2\eta_2}=\mu^2+\sigma^2,\qquad \frac{\partial^2 b}{\partial\eta_1^2}=-\frac{1}{2\eta_2}=\sigma^2.$$

这里有一个反直觉的现象

$\partial b/\partial\eta_2=\mu^2+\sigma^2$ 是**二阶原点矩** $\mathbb{E}[Y^2]$，**不是**方差。方差是 $\mathrm{Var}[Y]=\partial^2 b/\partial\eta_1^2=\sigma^2$。原因是：$t_2(y)=y^2$ 的"均值"本来就是二阶矩，只有在 $t(y)=y$ 的一参数模板里，$b'(\theta)$ 才直接等于 $\mathbb{E}[Y]$。

抽检：$\mu=2$，$\sigma^2=3$ 时 $\eta_1=2/3$、$\eta_2=-1/6$；$\partial b/\partial\eta_1=2=\mu$，$\partial b/\partial\eta_2=4+3=7=\mathbb{E}[Y^2]$，$\partial^2 b/\partial\eta_1^2=3=\sigma^2$。

这一小节的教学定位

课件 (1) 式的模板只覆盖"一个自然参数 + 一个离散度"。σ^2 未知时，严格说已经不在这个模板里，而在两参数指数族里。讲课时讲清这一点即可，不必展开矩阵形式：学生只要能回答"为什么这时没有 $a(\phi)$"就够了。

4.3 特例三：伯努利 Bernoulli

六步分解

【1】 $f(y;\pi)=\pi^y(1-\pi)^{1-y}$，$y\in\{0,1\}$。

【2】 $\log f=y\log\pi+(1-y)\log(1-\pi)$。

【3】 按 y 归并（把 y 从第二项里拆出来）：

$$\log f=y\big[\log\pi-\log(1-\pi)\big]+\log(1-\pi)=y\log\frac{\pi}{1-\pi}+\log(1-\pi).$$

【4】 取 $\theta=\log\dfrac{\pi}{1-\pi}$（即 logit），则 $\pi=\dfrac{e^\theta}{1+e^\theta}$、$1-\pi=\dfrac{1}{1+e^\theta}$，于是

$$\log(1-\pi)=-\log(1+e^\theta)\quad\Longrightarrow\quad b(\theta)=\log(1+e^\theta).$$

【5】 $a(\phi)=1$，$c(y;\phi)=0$。

【6】 $b'(\theta)=\dfrac{e^\theta}{1+e^\theta}=\pi$；$b''(\theta)=\dfrac{e^\theta}{(1+e^\theta)^2}=\pi(1-\pi)$；$\mathrm{Var}[Y]=b''=\pi(1-\pi)$。

θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	典则连接
$\log\dfrac{\mu}{1-\mu}$	1	1	$\log(1+e^{\theta})$	$\mu(1-\mu)$	$\operatorname{logit}(\mu)=\log\dfrac{\mu}{1-\mu}$

抽检：$\pi=0.3$ 时 $\theta=\operatorname{logit}(0.3)=-0.8473$，$b'(\theta)=0.3$，$b''(\theta)=0.21=\pi(1-\pi)$。

4.4 特例四：二项（计数版，帧 34）　Binomial, count version（frame 34）

六步分解

【1】$f(y;\pi)=\binom{n}{y}\pi^{y}(1-\pi)^{n-y}$，$y\in\{0,1,\dots,n\}$，$n$ 已知。

【2】$\log f=\log\binom{n}{y}+y\log\pi+(n-y)\log(1-\pi)$。

【3】按 y 归并：

$$\log f=y\log\frac{\pi}{1-\pi}+n\log(1-\pi)+\log\binom{n}{y}.$$

【4】$\theta=\log\dfrac{\pi}{1-\pi}$；由 $\log(1-\pi)=-\log(1+e^{\theta})$ 得

$$b(\theta)=n\log(1+e^{\theta}).$$

【5】$a(\phi)=1$，$c(y;\phi)=\log\binom{n}{y}$。

【6】$b'(\theta)=\dfrac{ne^{\theta}}{1+e^{\theta}}=n\pi$；$b''(\theta)=n\pi(1-\pi)$；$\operatorname{Var}[Y]=n\pi(1-\pi)$。

θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	典则连接
$\log\dfrac{\pi}{1-\pi}$	1	1	$n\log(1+e^{\theta})$	$\mu\left(1-\dfrac{\mu}{n}\right)$	$\log\dfrac{\mu}{n-\mu}$

抽检：$n=10$，$\pi=0.3$ 时 $\mu=n\pi=3$，$V(\mu)=3(1-0.3)=2.1$，而 $\operatorname{Var}[Y]=n\pi(1-\pi)=2.1$，两边一致。

计数版与比例版：本章最贵的一个区分

计数版（课件第 34 帧）：$Y\in\{0,\dots,n\}$，$\mu=n\pi$，$V(\mu)=\mu\left(1-\frac{\mu}{n}\right)$。
比例版：若响应是 $\hat{p}=Y/n$，则 $\mathbb{E}[\hat{p}]=\pi$，$\operatorname{Var}[\hat{p}]=\pi(1-\pi)/n$，方差函数是 $\mu(1-\mu)$（伯努利那一行），并带尺度 $a(\phi)=1/n$——等价于把 n 当作权重。
课件第 31 帧的方差函数表写的是伯努利（$\mu(1-\mu)$），第 34 帧的例子写的是计数（$n\log(1+e^{\theta})$）。**两处都对，但对应不同的响应定义。**考试里最典型的错误是：$b(\theta)$ 用了带 n 的版本，$V(\mu)$ 却写成 $\mu(1-\mu)$。

4.5 特例五：泊松（帧 33）　Poisson（frame 33）

六步分解

【1】$f(y;\mu)=\dfrac{\mu^{y}e^{-\mu}}{y!}$，$y=0,1,2,\dots$。

【2】$\log f=y\log\mu-\mu-\log y!$。

【3】已经归并好：y 的系数是 $\log\mu$，只含参数的项是 $-\mu$，只含数据的是 $-\log y!$。

【4】$\theta=\log\mu$，故 $\mu=e^{\theta}$，于是 $-\mu=-e^{\theta}$，即 $b(\theta)=e^{\theta}$。

【5】$a(\phi)=1$，$c(y;\phi)=-\log y!$。

【6】$b'(\theta)=e^{\theta}=\mu$；$b''(\theta)=e^{\theta}=\mu$；$\operatorname{Var}[Y]=\mu$。

θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	典则连接
$\log\mu$	1	1	e^{θ}	μ	$\log\mu$

抽检：$\mu = 2.5$ 时 $\theta = 0.9163$，$b' = b'' = 2.5$，故 $\mathbb{E}[Y] = \mathrm{Var}[Y] = 2.5$。

为什么泊松是最适合先讲的例子

它同时满足三件事：支撑是离散的（学生熟悉）；$b' = b'' = e^{\theta}$ 一算就出来（算术最干净）；均值等于方差（最能说明"异方差是结构性的"）。而且它与第 38 帧的泊松回归直接接上：$\theta = \log \mu$ 就是典则连接。

4.6 特例六：指数 Exponential

六步分解

【1】 $f(y;\lambda) = \lambda e^{-\lambda y}$，$y \geq 0$，$\lambda > 0$ 是**率**。
【2】 $\log f = \log \lambda - \lambda y$。
【3】 按 y 归并：$\log f = y\,(-\lambda) - \big(-\log \lambda\big)$。
【4】 $\theta = -\lambda$（故 $\lambda = -\theta$，且 $\theta < 0$），$b(\theta) = -\log(-\theta)$。
【5】 $a(\phi) = 1$，$c(y;\phi) = 0$。
【6】 $b'(\theta) = -\dfrac{1}{\theta} = \dfrac{1}{\lambda} = \mu$；$b''(\theta) = \dfrac{1}{\theta^2} = \dfrac{1}{\lambda^2} = \mu^2$；$\mathrm{Var}[Y] = \mu^2$。

θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	典则连接
$-\dfrac{1}{\mu}$	1	1	$-\log(-\theta)$	μ^2	$-\dfrac{1}{\mu}$

抽检：$\lambda = 0.5$ 时 $\mu = 2$，$\theta = -0.5$，$b'(\theta) = 2$，$b''(\theta) = 4 = \mu^2$。

符号与定义域

$\theta = -\lambda < 0$，所以 $b(\theta) = -\log(-\theta)$ 中的 $-\theta > 0$，对数有定义。学生如果写成 $b(\theta) = -\log \theta$，在 $\theta < 0$ 时直接出错。同理，伽马与逆高斯也都在 $\theta < 0$ 上定义。

4.7 特例七：伽马 Gamma

伽马有两种常用参数化，两种都要会：形状--速率 (α, λ) 是教科书形式，均值--离散度 (μ, β) 是 Tutorial 6 与 GLM 软件用的形式。两者的 (θ, b, V) 完全相同，只有 $c(y;\phi)$ 与 ϕ 的写法不同。

写法 (a)：形状--速率　shape--rate

六步分解

【1】 $f(y;\alpha,\lambda)=\dfrac{\lambda^{\alpha}}{\Gamma(\alpha)}y^{\alpha-1}e^{-\lambda y}$，$y>0$，$\alpha,\lambda>0$。

【2】 $\log f=\alpha\log\lambda-\lambda y+(\alpha-1)\log y-\log\Gamma(\alpha)$。

【3】 取 $\theta=-\dfrac{\lambda}{\alpha}=-\dfrac{1}{\mu}$（即 $\lambda=-\alpha\theta$），则

$$\alpha\log\lambda=\alpha\log(-\alpha\theta)=\alpha\log\alpha+\alpha\log(-\theta),$$

代回并凑出 $y\theta$：

$$\log f=\alpha\big[y\theta+\log(-\theta)\big]+\alpha\log\alpha+(\alpha-1)\log y-\log\Gamma(\alpha).$$

【4】 两边同除以 $\alpha=1/\phi$，即得 $\dfrac{y\theta-b(\theta)}{1/\alpha}$ 的形状，故

$$\phi=\frac{1}{\alpha},\qquad a(\phi)=\phi,\qquad b(\theta)=-\log(-\theta).$$

【5】

$$c(y;\phi)=\Big(\frac{1}{\phi}-1\Big)\log y+\frac{1}{\phi}\log\frac{1}{\phi}-\log\Gamma\Big(\frac{1}{\phi}\Big).$$

【6】 $b'(\theta)=-\dfrac{1}{\theta}=-\dfrac{1}{(-\lambda/\alpha)}=\dfrac{\alpha}{\lambda}=\mu$；$b''(\theta)=\dfrac{1}{\theta^2}=\mu^2$；$\mathrm{Var}[Y]=a(\phi)b''=\dfrac{1}{\alpha}\mu^2=\dfrac{\mu^2}{\alpha}$。

与伽马分布的已知结果核对：$\mathrm{Var}[Y]=\alpha/\lambda^2$，而 $\mu^2/\alpha=(\alpha/\lambda)^2/\alpha=\alpha/\lambda^2$，一致。

写法 (b)：均值--离散度（Tutorial 6）　mean--dispersion

同一套六步，只是把参数换成 (μ,β)

【1】

$$f(y;\mu,\beta)=\frac{1}{\Gamma(1/\beta)}\Big(\frac{y}{\beta\mu}\Big)^{1/\beta}\frac{1}{y}\exp\Big(-\frac{y}{\beta\mu}\Big),\qquad \mathbb{E}[Y]=\mu,\ \ \mathrm{Var}[Y]=\beta\mu^2.$$

【2】

$$\log f=-\log\Gamma(1/\beta)+\frac{1}{\beta}\big(\log y-\log\beta-\log\mu\big)-\log y-\frac{y}{\beta\mu}.$$

【3】 取 $\theta=-\dfrac{1}{\mu}$，则 $-\dfrac{y}{\mu}=y\theta$、$-\log\mu=\log(-\theta)$：

$$\log f=\frac{1}{\beta}\big[y\theta+\log(-\theta)\big]+\Big(\frac{1}{\beta}-1\Big)\log y-\frac{1}{\beta}\log\beta-\log\Gamma\Big(\frac{1}{\beta}\Big).$$

【4】 与 (a) 对照，$\phi=\beta$、$a(\phi)=\phi$、$b(\theta)=-\log(-\theta)$；**与 (a) 完全一样。**

【5】

$$c(y;\phi)=\Big(\frac{1}{\phi}-1\Big)\log y-\frac{1}{\phi}\log\phi-\log\Gamma\Big(\frac{1}{\phi}\Big).$$

【6】 同 (a)：$V(\mu)=\mu^2$，$\mathrm{Var}[Y]=\beta\mu^2$。

两种写法的关系与"必须记住的那一句"

$\beta=\dfrac{1}{\alpha}$，即**离散度是形状参数的倒数。**两种写法的 c 差一个只含 ϕ 的常数（$-\frac{1}{\phi}\log\frac{1}{\phi}$ 与 $-\frac{1}{\phi}\log\phi$ 互相抵消），对 θ 的推断没有影响。

伽马一行的全部答案： $\theta=-\dfrac{1}{\mu}$，$\phi=\dfrac{1}{\alpha}=\beta$，$a(\phi)=\phi$，$b(\theta)=-\log(-\theta)$，$V(\mu)=\mu^2$，典则连接 $g(\mu)=-\dfrac{1}{\mu}$。

伽马最容易错的地方：$\phi=\alpha$ 还是 $\phi=1/\alpha$

若把离散度错写成 $\phi=\alpha$，则 $\mathrm{Var}[Y]=a(\phi)b''(\theta)=\alpha\mu^2$，而正确结果是 μ^2/α。以 $\alpha=2,\lambda=3$ 为例：正确 $\mu=2/3$、$\mathrm{Var}=2/9\approx0.2222$、$a(\phi)=1/2$；错误写法会给出 $\mathrm{Var}=2\times(2/3)^2=0.8889$，大四倍。

4.8 特例八：逆高斯 Inverse Gaussian

逆高斯（inverse Gaussian）是 μ^3 那一行。它的密度比前几个复杂，但六步法照旧——真正需要练的是"把 $-\lambda/(2y)$ 认出来，它属于 c 而不是 b"。

六步分解

【1】取均值 μ、形状 λ 的参数化：

$$f(y;\mu,\lambda)=\sqrt{\frac{\lambda}{2\pi y^3}}\exp\Big\{-\frac{\lambda(y-\mu)^2}{2\mu^2 y}\Big\},\qquad y>0,\ \ \mathbb{E}[Y]=\mu,\ \ \mathrm{Var}[Y]=\frac{\mu^3}{\lambda}.$$

【2】

$$\log f=\frac{1}{2}\log\lambda-\frac{1}{2}\log(2\pi)-\frac{3}{2}\log y-\frac{\lambda(y-\mu)^2}{2\mu^2 y}.$$

【3】展开 $\dfrac{(y-\mu)^2}{\mu^2 y}=\dfrac{y}{\mu^2}-\dfrac{2}{\mu}+\dfrac{1}{y}$，代回：

$$\log f=-\frac{\lambda}{2\mu^2}y+\frac{\lambda}{\mu}-\frac{\lambda}{2y}-\frac{3}{2}\log y+\frac{1}{2}\log\lambda-\frac{1}{2}\log(2\pi).$$

【4】y 的系数是 $-\dfrac{\lambda}{2\mu^2}$。取 $a(\phi)=\phi=\dfrac{1}{\lambda}$，则 $\theta=-\dfrac{1}{2\mu^2}$，且

$$-\frac{b(\theta)}{a(\phi)}=\frac{\lambda}{\mu}\ \Longrightarrow\ b(\theta)=-\frac{1}{\mu}=-\sqrt{-2\theta}\quad(\theta<0).$$

【5】

$$c(y;\phi)=-\frac{1}{2\phi y}-\frac{3}{2}\log y-\frac{1}{2}\log(2\pi\phi).$$

注意 $-\dfrac{\lambda}{2y}=-\dfrac{1}{2\phi y}$ 只含 y 与 ϕ，所以它进 c，**不进** b。

【6】

$$b'(\theta)=(-2\theta)^{-1/2}=\mu,\qquad b''(\theta)=(-2\theta)^{-3/2}=\mu^3,\qquad \mathrm{Var}[Y]=\frac{1}{\lambda}\mu^3=\frac{\mu^3}{\lambda}.$$

θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	典则连接
$-\dfrac{1}{2\mu^2}$	$\dfrac{1}{\lambda}$	ϕ	$-\sqrt{-2\theta}$	μ^3	$-\dfrac{1}{2\mu^2}$

抽检：$\mu=2,\ \lambda=5$ 时 $\theta=-0.125$，$b'(\theta)=2$，$b''(\theta)=8$，$\mathrm{Var}=8/5=1.6=\mu^3/\lambda$。

逆高斯最容易错的地方

(i) 把 $-\dfrac{\lambda}{2y}$ 归进 $b(\theta)$：它含 y，必须进 $c(y;\phi)$。

(ii) 忘记 $\theta<0$ 时的平方根取正支：$b(\theta)=-\sqrt{-2\theta}$（前面有负号），否则 b' 会得到 $-\mu$。

4.9 三个"不属于"的例子 Three cases that do not fit

均匀分布 $U(0,\theta)$：支撑依赖参数　Uniform: parameter-dependent support

为什么出局

$$f(y;\theta)=\frac{1}{\theta}\mathbf{1}\{0\le y\le\theta\}.$$

理由一（结构）：指示函数 $\mathbf{1}\{y\le\theta\}$ 依赖 θ 与 y 的**比较**，不能写成 $\exp\{y\theta-b(\theta)+c(y)\}$ 的形式——指数族要求 θ 与 y 只通过乘积 $y\theta$ 相遇。
理由二（定理的前提）：即使强行写成 $\log f=-\log\theta+\log\mathbf{1}\{y\le\theta\}$，"密度积分为 1"的积分上限依赖 θ，求导时会出现边界项，均值方差定理的前提不成立。
这也正是均匀分布的极大似然估计落在边界 $\hat\theta=y_{(n)}$、导数处处不为零的原因（第 1.9 节）。

韦布尔：形状已知与形状未知是两回事　Weibull: known vs unknown shape

形状 k 已知：可以写，但充分统计量是 y^k 而不是 y

$f(y;k,\lambda)=\dfrac{k}{\lambda}\Big(\dfrac{y}{\lambda}\Big)^{k-1}\exp\Big\{-\Big(\dfrac{y}{\lambda}\Big)^{k}\Big\}$。取 $\theta=-\lambda^{-k}$，则

$$\log f=\theta\,y^k+\log(-\theta)+\log k+(k-1)\log y.$$

这是指数族，但**统计量是** $t(y)=y^k$，不是 y。因此课件 (1) 式的模板（"$y\theta$"）不能直接套：在这里

$$b'(\theta)=-\frac{1}{\theta}=\lambda^k=\mathbb{E}[Y^k],\qquad\text{而}\qquad\mathbb{E}[Y]=\lambda\Gamma\Big(1+\frac{1}{k}\Big)\neq\lambda^k.$$

数值上取 $k=1.7,\ \lambda=2$：$b'(\theta)=3.249$，而 $\mathbb{E}[Y]=1.784$；$a(\phi)b''(\theta)=10.556$，而 $\mathrm{Var}[Y]=1.167$。**两个核对都失败**——这就是"模板不适用"的证据。

若一定要给韦布尔一个方差函数，可以验证 $\mathrm{Var}[Y]=c(k)\,\mu^2$，其中

$$c(k)=\frac{\Gamma(1+2/k)}{\Gamma(1+1/k)^2}-1,\qquad c(1.7)=0.3666,\quad c(1)=1.$$

$k=1$ 时退化为指数分布（$c=1$，$V(\mu)=\mu^2$），与特例六一致。但这个 V 不是由 $a(\phi)b''(\theta)$ 得来的，只能说"碰巧形如 μ^2"。

形状 k 未知：不属于指数族

k 出现在统计量**自身**的幂次上（y^k），也出现在系数 $(k-1)\log y$ 里。于是：

- 充分统计量 $(\sum\log y_i,\ \sum y_i^k)$ 的**函数形式随参数 k 改变**，不是固定的 $t(y)$；
- 因此不存在"固定个数的自然参数"使密度写成 $\sum\theta_i t_i(y)-b(\boldsymbol{\theta})+c(y)$。

这正是指数族定义里"统计量不依赖参数"这条隐含要求的用武之地。

4.10　总表与记忆法　Master table and how to remember it

分布	θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	典则连接 $g(\mu)$
$\mathrm{N}(\mu,\sigma^2)$	μ	σ^2	ϕ	$\theta^2/2$	1	μ
伯努利(π)	$\log\dfrac{\pi}{1-\pi}$	1	1	$\log(1+e^\theta)$	$\mu(1-\mu)$	$\log\dfrac{\mu}{1-\mu}$
$\mathrm{Binomial}(n,\pi)$	$\log\dfrac{\pi}{1-\pi}$	1	1	$n\log(1+e^\theta)$	$\mu\Big(1-\dfrac{\mu}{n}\Big)$	$\log\dfrac{\mu}{n-\mu}$
$\mathrm{Poisson}(\mu)$	$\log\mu$	1	1	e^θ	μ	$\log\mu$
$\mathrm{Exp}(\lambda)$	$-\dfrac{1}{\mu}$	1	1	$-\log(-\theta)$	μ^2	$-\dfrac{1}{\mu}$
$\mathrm{Gamma}(\mu,\beta)$	$-\dfrac{1}{\mu}$	β	ϕ	$-\log(-\theta)$	μ^2	$-\dfrac{1}{\mu}$
$\mathrm{IG}(\mu,\lambda)$	$-\dfrac{1}{2\mu^2}$	$\dfrac{1}{\lambda}$	ϕ	$-\sqrt{-2\theta}$	μ^3	$-\dfrac{1}{2\mu^2}$

分布	$c(y;\phi)$
$\mathrm{N}(\mu,\sigma^2)$	$-\dfrac{y^2}{2\phi}-\dfrac{1}{2}\log(2\pi\phi)$
伯努利	0
$\mathrm{Binomial}(n,\pi)$	$\log\binom{n}{y}$
$\mathrm{Poisson}(\mu)$	$-\log y!$
$\mathrm{Exp}(\lambda)$	0
$\mathrm{Gamma}(\mu,\beta)$	$\left(\dfrac{1}{\phi}-1\right)\log y-\dfrac{1}{\phi}\log\phi-\log\Gamma\left(\dfrac{1}{\phi}\right)$
$\mathrm{IG}(\mu,\lambda)$	$-\dfrac{1}{2\phi y}-\dfrac{3}{2}\log y-\dfrac{1}{2}\log(2\pi\phi)$

三条记忆线索

(1) 先记 b，V 是送的。 $V(\mu)=b''(\theta(\mu))$，所以只要能反解 $\mu=b'(\theta)$，方差函数不用背。
(2) "负号家族"：指数、伽马、逆高斯的 θ 都是负的（$\theta=-1/\mu$、$-1/(2\mu^2)$），因此 b 里出现 $\log(-\theta)$ 与 $\sqrt{-2\theta}$。看到 $\theta<0$ 不要慌，那是定义域。
(3) 离散型的 c 只有组合数或阶乘，连续型的 c 才含 $\log y$。 用这条可以快速判断自己有没有把数据项错放进 b。

从 $V(\mu)$ 反查分布：$V=1$ 正态，$V=\mu$ 泊松，$V=\mu^2$ 伽马/指数，$V=\mu^3$ 逆高斯，$V=\mu(1-\mu)$ 伯努利。第 5 章的 IRLS 只需要 V 与 g——给定这两样，算法与分布无关。这也是"方差函数"这一概念在整个模块里最实用的地方。

4.11 四个高频错误　Four errors that cost marks

错误 1：把 $-\dfrac{y^2}{2\sigma^2}$ 放进 $b(\theta)$

任何含 y 的项都不能进 $b(\theta)$。正态的 $-\dfrac{y^2}{2\sigma^2}$ 与逆高斯的 $-\dfrac{\lambda}{2y}$ 都属于 $c(y;\phi)$。

错误 2：伽马的 ϕ 写成 α

$\phi=1/\alpha=\beta$。写错会让方差差一个 α^2 的因子（$\alpha\mu^2$ 对 μ^2/α）。

错误 3：二项的 b 带 n、V 却不带 n

$b(\theta)=n\log(1+e^\theta)$ 与 $V(\mu)=\mu\left(1-\frac{\mu}{n}\right)$ 必须成对出现；要么两处都按计数版，要么两处都按比例版（这时 $a(\phi)=1/n$）。

错误 4：以为 $c(y;\phi)$ 不能含 ϕ

c 只要求**不含** θ，完全可以含 ϕ（正态的 $-\frac{1}{2}\log(2\pi\phi)$、伽马的 $-\log\Gamma(1/\phi)$）。学生在这一点上卡住，往往是因为把 c 误记成"只含 y"。

5 连接函数　Link Functions（帧 35--39）

第 4 节把"随机成分"讲完了：选一个指数族分布，就自动有了 $V(\mu)$。这一节讲第二个自由度——均值怎样连到线性预测子。课件第 35--36 帧给定义与清单一，第 37--39 帧给四个具体模型。核心概念只有一个：**典则连接。**

5.1 定义与两条要求　Definition and two requirements（帧 35）

定义

连接函数 g 把均值 μ 映到线性预测子 η：

$$\eta_i = g(\mu_i) = \mathbf{x}_i^\top \boldsymbol{\beta}, \qquad \Longleftrightarrow \qquad \mu_i = g^{-1}(\mathbf{x}_i^\top \boldsymbol{\beta}).$$

要求：**(1)** g 在均值的取值范围内**严格单调**（于是可逆）；**(2)** g 可微。

严格单调这一条不是形式要求，它保证"给定 η 有唯一的 μ"，否则模型无法定义。可微是为了后面用 Newton 法求 $\boldsymbol{\beta}$。

第三条要求：值域必须对得上（课件没明说，但必考）

$\eta = \mathbf{x}^\top\boldsymbol{\beta}$ 可以取任意实数，而 μ 往往被限制在某个子集里：泊松 $\mu > 0$、二项 $0 < \pi < 1$、伽马 $\mu > 0$。所以 g^{-1} 必须把 $\mathbb{R}$ 映回这个子集。反过来讲：**恒等连接只对"均值可以取任意实数"的正态模型合法。**

5.2 典则连接　The canonical link

定义与存在性证明

定义： 若 $g(\mu) = \theta(\mu) = (b')^{-1}(\mu)$，则称 g 为**典则连接**（canonical link）。也就是说：连接函数恰好等于自然参数。

证明它总存在： 由均值方差定理，$b''(\theta) = \mathrm{Var}[Y]/a(\phi) > 0$，所以 b' 严格递增；严格递增函数在其值域上可逆。于是对每个 μ 都存在唯一的 θ 使 $b'(\theta) = \mu$，取 $g(\mu) = \theta$ 即可。

分布	自然参数 θ	典则连接 $g(\mu) = \theta(\mu)$	逆 $g^{-1}(\eta)$
正态	μ	μ	η
伯努利 / 二项	$\log\dfrac{\pi}{1-\pi}$	$\log\dfrac{\mu}{1-\mu}$　(或 $\log\dfrac{\mu}{n-\mu}$)	$\dfrac{e^\eta}{1+e^\eta}$
泊松	$\log\mu$	$\log\mu$	e^η
指数 / 伽马	$-\dfrac{1}{\mu}$	$-\dfrac{1}{\mu}$	$-\dfrac{1}{\eta}$
逆高斯	$-\dfrac{1}{2\mu^2}$	$-\dfrac{1}{2\mu^2}$	$(-2\eta)^{-1/2}$

典则连接带来三件"免费的"好处（第 5 章要用）

(1) 得分方程变成残差与自变量正交。 当 $\eta_i = \theta_i = \mathbf{x}_i^\top\boldsymbol{\beta}$ 时，

$$\frac{\partial \ell}{\partial \boldsymbol{\beta}} = \sum_{i=1}^{n} \frac{y_i - \mu_i}{a(\phi)}\,\mathbf{x}_i = \frac{1}{a(\phi)}\mathbf{X}^\top(\mathbf{y} - \boldsymbol{\mu}) = \mathbf{0} \iff \mathbf{X}^\top\mathbf{y} = \mathbf{X}^\top\boldsymbol{\mu}.$$

(2) 观测信息等于期望信息。 海森矩阵是 $-\dfrac{1}{a(\phi)}\mathbf{X}^\top\mathbf{W}\mathbf{X}$，其中 $\mathbf{W} = \mathrm{diag}\big(V(\mu_i)\big)$，不依赖 $\mathbf{y}$，于是 Newton--Raphson 与 Fisher scoring 给出同一步。 **(3) 对数似然关于 $\boldsymbol{\beta}$ 凹。** $\mathbf{X}^\top\mathbf{W}\mathbf{X}$ 正定（$\mathbf{W}$ 对角元为正），所以海森矩阵负定，极大值唯一。

这三条正是"为什么教材偏爱典则连接"的全部理由。第 5 章的 IRLS 在工作变量与权重上迭代，而典则连接让这一步退化成"加权最小二乘"，实现最简单。

5.3 常见连接一览　A catalogue of links（帧 36）

名称	$g(\mu)$	$g^{-1}(\eta)$	均值范围	典型用途
恒等 identity	μ	η	$\mathbb{R}$	正态线性模型
对数 log	$\log\mu$	e^{η}	$\mu>0$	计数、伽马、指数族中正值响应
平方根 sqrt	$\sqrt{\mu}$	η^2	$\mu\geq 0$	泊松（方差稳定）
倒数 inverse	μ^{-1}	η^{-1}	$\mu>0$	伽马、逆高斯（典则）
对数几率 logit	$\log\dfrac{\mu}{1-\mu}$	$\dfrac{e^{\eta}}{1+e^{\eta}}$	$0<\mu<1$	二分类、比例（典则）
概率单位 probit	$\Phi^{-1}(\mu)$	$\Phi(\eta)$	$0<\mu<1$	二分类（潜变量正态）
互补对数对数 cloglog	$\log\{-\log(1-\mu)\}$	$1-e^{-e^{\eta}}$	$0<\mu<1$	二分类（非对称、极端概率）

平方根连接的方向

$g(\mu)=\sqrt{\mu}$ 的逆是 $\mu=\eta^2$，所以要求 $\eta\geq 0$——严格说它把 η 限制在半直线上，与"η 可取任意实数"不一致。实践中要么在拟合时加约束，要么干脆用 log 连接。这一点课件没有展开，考试不会考，但学生问起要能答。

5.4 四个具体模型　Four concrete models（帧 37--39）

高斯响应 + 恒等连接 = 线性回归（帧 37）　Gaussian + identity

三组件写全

随机成分： $Y_i\sim \mathrm{N}(\mu_i,\sigma^2)$ 独立；
系统成分： $\eta_i=\mathbf{x}_i^{\top}\boldsymbol{\beta}$；
连接： $\theta_i=\mu_i=\eta_i$（典则），即 $\mu_i=\mathbf{x}_i^{\top}\boldsymbol{\beta}$。

这是唯一一个"三个组件都还是老样子"的 GLM，也是第 2、3 章的模型。它的 $V(\mu)=1$，所以 $\mathrm{Var}[Y]=\sigma^2$ 与 μ 无关——这正是"同方差"在 GLM 语言里的说法。

泊松响应 + 对数连接 = 泊松回归（帧 38）　Poisson + log

三组件写全

随机成分： $Y_i\sim \mathrm{Poisson}(\mu_i)$ 独立，$\mathbb{E}[Y_i]=\mathrm{Var}[Y_i]=\mu_i$；
系统成分： $\eta_i=\mathbf{x}_i^{\top}\boldsymbol{\beta}$；
连接： $\theta_i=\log\mu_i=\eta_i$（典则），即 $\mu_i=\exp(\mathbf{x}_i^{\top}\boldsymbol{\beta})$。

系数的解释

β_j 增加 1 个单位，μ 变为原来的 e^{β_j} 倍（multiplicative）。所以泊松回归的系数常被报成"率比"（rate ratio）$e^{\hat\beta_j}$。这与"对 $\log Y$ 做线性回归"的解释看起来一样，但方差结构完全不同（见 2.3 的易错框）。

二项响应 + logit 连接 = logistic 回归（帧 39）　Binomial + logit

三组件写全（两种写法）

(a) 伯努利响应（$n_i=1$）：$Y_i\sim \mathrm{Bernoulli}(\pi_i)$，

$$\mathrm{logit}(\pi_i)=\log\frac{\pi_i}{1-\pi_i}=\mathbf{x}_i^{\top}\boldsymbol{\beta}\iff \pi_i=\frac{\exp(\mathbf{x}_i^{\top}\boldsymbol{\beta})}{1+\exp(\mathbf{x}_i^{\top}\boldsymbol{\beta})}.$$

(b) 分组二项（n_i 次试验）：$Y_i\sim \mathrm{Binomial}(n_i,\pi_i)$，$\mathbb{E}[Y_i]=n_i\pi_i$，

$$\mathrm{logit}(\pi_i)=\mathbf{x}_i^{\top}\boldsymbol{\beta},\qquad V(\mu_i)=\mu_i\Big(1-\frac{\mu_i}{n_i}\Big).$$

logistic 的两种解释

(1) 几率比（odds ratio）：e^{β_j} 是 x_j 增加 1 单位时优势（odds）的倍数。
(2) 潜变量：设 $Y^* = \mathbf{x}^\top\boldsymbol{\beta} + \varepsilon$，$\varepsilon$ 服从标准 logistic 分布，则 $\Pr(Y=1 \mid \mathbf{x}) = \text{logistic}(\mathbf{x}^\top\boldsymbol{\beta})$。若 ε 服从正态，就得到 probit。

二项响应 + probit 连接 = probit 回归（帧 39）　Binomial + probit

把 logit 换成 Φ^{-1}

$$g(\pi_i) = \Phi^{-1}(\pi_i) = \mathbf{x}_i^\top\boldsymbol{\beta} \iff \pi_i = \Phi(\mathbf{x}_i^\top\boldsymbol{\beta}),$$

其中 Φ 是标准正态的分布函数。随机成分与 logistic 相同，只是连接不同，所以**方差函数相同**（$\mu(1-\mu)$ 或 $\mu(1-\mu/n)$），只有连接变了。

logit 与 probit 的差别在哪

两者形状几乎一样（$\text{logistic}(\eta) \approx \Phi(1.6\,\eta)$，差一个约 1.6 的尺度），差别在**尾部**：logit 的尾更厚。所以：(i) 两者的系数不能直接比较，必须乘以尺度因子或用平均边际效应（AME）；(ii) 极端概率（接近 0 或 1）时选择哪个会给出不同结论。考试若问"系数为什么不同"，答"连接不同、尺度不同、但拟合的均值几乎相同"。

5.5 非典则连接：什么时候用、代价是什么　Non-canonical links: when and at what cost

课件只给了一个清单，没有说"为什么不用典则连接"。这个问题值得两分钟：

场景	选的连接	理由
伽马的均值建模	对数 $\log\mu$	系数可解释为"倍数"；保证 $\mu>0$；比倒数连接稳定
泊松的方差稳定	平方根 $\sqrt{\mu}$	$\sqrt{Y}$ 的方差近似常数（经典变换）
二分类的对称性	probit	潜变量正态，与生物统计的阈值模型一致
极端概率的偏斜	cloglog	由生存/风险模型导出，尾部不对称
可加风险	恒等	风险差（risk difference）可直接解释，但需约束 $\mu\in(0,1)$

非典则连接的三项代价

(1) 得分方程不再是 $\mathbf{X}^\top(\mathbf{y}-\boldsymbol{\mu})=\mathbf{0}$，没有"残差正交"这个漂亮的解释；
(2) 观测信息 $\neq$ 期望信息，Newton--Raphson 与 Fisher scoring 不再重合，需要选一个；
(3) 对数似然关于 β 不一定凹，可能有多峰或迭代不收敛，需要好的初值与步长控制。

一句话总结这一节：**分布决定方差函数，连接决定均值怎样进入模型。**两者合起来才确定一个 GLM；典则连接是"数学上最省事"的搭配，但不是唯一正确的搭配。

6 模型设定总结　Summary of Model Specification（帧 40--41）

最后两帧把整章收成两行方程与三个组件。这一节把它们写成一份可以直接照抄的"设定模板"，再给三份完整的模型设定示例。

6.1 两行方程与三个组件　Two equations and three components（帧 41）

GLM 的定义

$$\text{(1)}\quad \mathbf{y} = \boldsymbol{\mu} + \boldsymbol{\varepsilon}, \qquad \text{(2)}\quad g(\boldsymbol{\mu}) = \mathbf{X}\boldsymbol{\beta}.$$

三个组件（给定 n 个观测、p 个自变量）：

1. **随机成分**：响应的分布，限制在某个指数族内，均值 $\boldsymbol{\mu} = \mathbb{E}[\mathbf{y}]$；
2. **系统成分**：$\eta = \mathbf{X}\boldsymbol{\beta}$，其中 $\mathbf{X} \in \mathbb{R}^{n\times(p+1)}$、$\boldsymbol{\beta} \in \mathbb{R}^{p+1}$；
3. **连接**：$\eta = g(\boldsymbol{\mu})$，即 $\eta_i = g(\mu_i)$，$i = 1, \ldots, n$。

	随机成分	系统成分	连接
线性回归	$Y_i \sim \mathrm{N}(\mu_i, \sigma^2)$	$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$	$\mu_i = \eta_i$
泊松回归	$Y_i \sim \mathrm{Poisson}(\mu_i)$	$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$	$\log \mu_i = \eta_i$
logistic 回归	$Y_i \sim \mathrm{Bernoulli}(\pi_i)$	$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$	$\mathrm{logit}(\pi_i) = \eta_i$
probit 回归	$Y_i \sim \mathrm{Bernoulli}(\pi_i)$	$\eta_i = \mathbf{x}_i^\top \boldsymbol{\beta}$	$\Phi^{-1}(\pi_i) = \eta_i$

四个模型的系统成分完全相同——这就是第 2 节那句话的最终形态：**线性预测子不变，换的只是随机成分与连接。**

6.2 三份完整设定示例　Three complete specifications

示例 1：正态线性回归（第 1--3 章的模型）

设 Y_i 独立，$Y_i \sim \mathrm{N}(\mu_i, \sigma^2)$，$\mu_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$，$i = 1, \ldots, n$。
等价写法：$\boldsymbol{\mu} = \mathbf{X}\boldsymbol{\beta}$，$\mathrm{Var}[Y_i] = \sigma^2$（常数），$V(\mu) = 1$，$g$ 为恒等连接。

示例 2：泊松对数线性模型

设 Y_i 独立，$Y_i \sim \mathrm{Poisson}(\mu_i)$，$\log \mu_i = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip}$，即 $\mu_i = \exp(\mathbf{x}_i^\top \boldsymbol{\beta})$；$\mathrm{Var}[Y_i] = \mu_i$，$V(\mu) = \mu$，$g$ 为对数连接（典则）。

示例 3：logistic 回归（伯努利响应）

设 Y_i 独立，$Y_i \sim \mathrm{Bernoulli}(\pi_i)$，

$$\mathrm{logit}(\pi_i) = \log \frac{\pi_i}{1-\pi_i} = \beta_0 + \beta_1 x_{i1} + \cdots + \beta_p x_{ip} \iff \pi_i = \frac{\exp(\mathbf{x}_i^\top \boldsymbol{\beta})}{1 + \exp(\mathbf{x}_i^\top \boldsymbol{\beta})};$$

$\mathrm{Var}[Y_i] = \pi_i(1-\pi_i)$，$V(\mu) = \mu(1-\mu)$，$g$ 为 logit（典则）。

6.3 建模前的检查清单　A checklist before fitting

八项检查（按顺序做）

1. **响应的取值范围**是什么？$\mathbb{R}$（正态）、$\{0, 1, \ldots\}$（泊松）、$\{0, \ldots, n\}$（二项）、$(0, \infty)$（伽马/指数）。
2. 响应的**方差是否随均值变化**？是，则不要用正态。
3. 选出**分布** $\Rightarrow$ 写出 $V(\mu)$ 与 $a(\phi)$。
4. 选出**连接** g：先看典则是否合适；不合适再换（log、probit、cloglog 等）。
5. 检查 g^{-1} 的**值域**是否与 μ 的范围一致。
6. 写出**两行方程**与**三组件**。
7. 检查设计矩阵 $\mathbf{X}$ 的**维数**与共线性。
8. 想清楚系数的**解释**（倍数、几率比、边际效应）。

6.4 与第 5、6 章的接口　Bridge to Chapters 5 and 6

本章停在"模型怎么设定"。接下来两章各接一条线： **第 5 章**接"怎么估"：得分方程

$$\sum_{i=1}^{n} \frac{(y_i - \mu_i)\, x_{ij}}{a(\phi) V(\mu_i)} = 0, \qquad j = 0, 1, \ldots, p$$

一般没有闭式解，需要 Newton--Raphson / Fisher scoring / IRLS；典则连接时它退化成加权最小二乘。 **第 6 章**接"怎么查"：偏差（deviance）、残差与诊断，它们的定义都建立在指数族的对数似然之上（$2\{\ell(\text{饱和模型}) - \ell(\text{当前模型})\}$）。所以本章的 $b(\theta)$ 与 $c(y;\phi)$ 不是形式上的装饰，它们是后面所有统计量的原料。

7 讲课防错清单　Sixteen Pitfalls, and How to Pre-empt Them

这一节可以单独印一页，上课前扫一遍。每一条给出：**错误**（学生或讲者会写成的样子）、**正确**、**预防**（一句话，可直接在课堂上说）。

1. **二项 MLE 的分母。** **错误**：$\hat\theta = \sum y_i/4$；**正确**：$\hat\theta = \sum y_i/(4\times 3) = 8/12$。**预防**："分母是试验**总次数**，不是观测个数。"
2. **指数分布的参数当均值。** **错误**：$\hat\theta = \bar y = 2.1625$；**正确**：$\hat\theta = 1/\bar y = 0.4624$。**预防**："$\theta$ 是率，rate, not mean。"
3. **"对数似然的最大值等于似然的最大值"。** **错误**：用 $\ell(\hat\theta)$ 代替 $L(\hat\theta)$ 比较大小。**正确**：两者只共享最大值的位置，不共享数值。**预防**："argmax 同，max 不同。"
4. **忘记二阶导（或海森）检验。** **正确**：二项题 $\ell'' < 0$；正态题 $\partial^2\ell/\partial\theta_1^2 < 0$ 且 $\det(\mathbf{H}) > 0$。**预防**："一阶导为零只给驻点；极大值要二阶条件。"
5. **正态方差的 MLE 除以 $n-1$。** **错误**：$\hat\sigma^2 = s^2$；**正确**：$\hat\sigma^2 = \frac{1}{n}\sum(y_i - \bar y)^2$，期望是 $\frac{n-1}{n}\sigma^2$。**预防**："MLE 不保证无偏；无偏是另一条判据。"
6. **认为 MLE 总有解析解。** **预防**："均匀分布的反例：最大在边界，导数处处不为零。"
7. **把"对响应取 $\log$"当成"用 $\log$ 连接"。** **错误**："两个模型一样，只是写法不同。"**正确**：前者改数据（对数正态，$\mathbb{E}[Y] = e^{\mathbf{x}^\top\boldsymbol\beta + \sigma^2/2}$），后者只改均值的连接（泊松，$\mathrm{Var}[Y] = \mu$）。**预防**："变换的是数据还是均值？"
8. **把含 y 的项放进 $b(\theta)$。** **错误**：正态的 $-\frac{y^2}{2\sigma^2}$、逆高斯的 $-\frac{\lambda}{2y}$ 归入 b。**预防**："b 里只有参数；含 y 的一律进 $c(y;\phi)$。"
9. **伽马的离散度写成 α。** **错误**：$\phi = \alpha$，导致 $\mathrm{Var}[Y] = \alpha\mu^2$；**正确**：$\phi = 1/\alpha = \beta$，$\mathrm{Var}[Y] = \mu^2/\alpha$。**预防**："拿 $a(\phi)V(\mu)$ 一验，就知道差四倍。"
10. **二项：b 带 n、V 不带 n。** **错误**：$b = n\log(1+e^\theta)$ 配 $V(\mu) = \mu(1-\mu)$；**正确**：$V(\mu) = \mu(1-\mu/n)$（计数版），或两处都按比例版（$a(\phi) = 1/n$）。
11. **伯努利与二项混用。** **预防**："先问：响应是 0/1、是 0 到 n 的计数、还是比例？"
12. **认为 $c(y;\phi)$ 不能含 ϕ。** **正确**：c 只要求不含 θ——正态的 $-\frac{1}{2}\log(2\pi\phi)$、伽马的 $-\log\Gamma(1/\phi)$ 都在 c 里。
13. **忽略 θ 的定义域。** **错误**：$b(\theta) = -\log\theta$（伽马/指数）、$b(\theta) = \sqrt{-2\theta}$（逆高斯）。**正确**：$\theta < 0$，故 $b(\theta) = -\log(-\theta)$、$b(\theta) = -\sqrt{-2\theta}$。
14. **把典则连接说成"唯一正确"或"最好的"连接。** **正确**：典则连接让得分方程最简、信息矩阵最漂亮；但可解释性、值域与数值稳定性常常要求非典则连接。
15. **对计数或比例数据用"正态 + 恒等连接"。** **错误**：预测值出现负数、标准误偏小。**预防**："响应有界或非负，恒等连接就不合法。"
16. **直接比较 logit 与 probit 的系数。** **正确**：两者差一个约 1.6 的尺度；应比较平均边际效应或标准化系数。

如果只能记三条

(1) $b'(\theta)=\mu$ 与 $a(\phi)b''(\theta)=\mathrm{Var}[Y]$ 两条核对必须都做。
(2) 伽马的 $\phi=1/\alpha$。
(3) log 变换 $\neq$ log 连接。

8　数值核对表　Every Number in This Note, and How to Re-check It

下表列出本讲义出现的每个关键数字，都可以用 `verify_edf.py`（本目录下）重算。讲课时如果学生质疑某个结果，直接报这里的数字即可。

第 1 节：极大似然估计

量	数值	结果
二项：观测和 $\sum y_i$	$1+3+2+2=8$	—
二项：试验总数 nm	$4\times 3=12$	—
二项：组合系数积	$3\cdot 1\cdot 3\cdot 3=27$	$L(\theta)=27\theta^8(1-\theta)^4$
二项：MLE	$8/12$	$\hat\theta=0.6667$
二项：二阶导在 MLE	$-8/(4/9)-4/(1/9)$	-54
二项：ℓ 在 0.5, 2/3, 0.8	$-8.3178,\ -7.6382,\ -8.2229$	最大值在 $2/3$
二项：　$L(2/3)$	1.3006×10^{-2}	—
指数：观测和	$1.23+3.32+1.98+2.12=8.65$	—
指数：样本均值	$8.65/4=2.1625$	—
指数：MLE	$4/8.65$	$\hat\theta=0.462428$
指数：　$\ell(\hat\theta)$	$4\log\hat\theta-8.65\hat\theta$	-7.0851
指数：　L 在 0.25, 0.5, $\hat\theta$	$4.49,\ 8.27,\ 8.38\ (\times 10^{-4})$	最大值在 $\hat\theta$
正态：样本均值	$(1.2+2.4+0.9+3.1+2.6)/5$	$\bar y=2.0400$
正态：方差 MLE	除 $n=5$	$\hat\sigma^2=0.7144$
正态：无偏方差	除 $n-1=4$	$s^2=0.8930$
正态：偏差因子	$0.7144/0.8930$	$0.8000=(n-1)/n$
正态：海森对角元	$n/\hat\sigma^2,\ n/(2\hat\sigma^4)$	$-6.9989,\ -4.8984$

第 4 节：八个特例的抽检

分布	参数	μ	$\mathrm{Var}[Y]$	$a(\phi)$	$V(\mu)$
正态	$\mu=3,\ \sigma^2=4$	3	4	4	1
伯努利	$\pi=0.3$	0.3	0.21	1	0.21
二项	$n=10,\ \pi=0.3$	3	2.1	1	2.1
泊松	$\mu=2.5$	2.5	2.5	1	2.5
指数	$\lambda=0.5$	2	4	1	4
伽马	$\alpha=2,\ \lambda=3$	0.6667	0.2222	0.5	0.4444
逆高斯	$\mu=2,\ \lambda=5$	2	1.6	0.2	8

右两列相乘恒等于左两列的方差：例如伽马 $a(\phi)V(\mu)=0.5\times 0.4444=0.2222=\mathrm{Var}[Y]$。这张表就是第 6 步核对的一次总演练。

典则参数与两参数正态

量	计算	数值
伯努利 θ（$\pi = 0.3$）	$\log(0.3/0.7)$	-0.8473
二项 θ（$n = 10,\ \mu = 3$）	$\log(3/7)$	-0.8473
泊松 θ（$\mu = 2.5$）	$\log 2.5$	0.9163
指数 θ（$\lambda = 0.5$）	$-\lambda$	-0.5
伽马 θ（$\alpha = 2,\ \lambda = 3$）	$-\lambda/\alpha = -1/\mu$	-1.5
逆高斯 θ（$\mu = 2$）	$-1/(2\mu^2)$	-0.125
两参数正态	$\mu = 2,\ \sigma^2 = 3$	$\eta_1 = 0.6667,\ \eta_2 = -0.1667$
$\partial b/\partial\eta_1$	$= \mu$	2
$\partial b/\partial\eta_2$	$= \mu^2 + \sigma^2$	7
$\partial^2 b/\partial\eta_1^2$	$= \sigma^2$	3

韦布尔的两个"失败"数字

量（$k = 1.7,\ \lambda = 2$）	模板给出	真实值
$b'(\theta)$ 对 $\mathbb{E}[Y]$	3.249	1.784
$a(\phi)b''(\theta)$ 对 $\mathrm{Var}[Y]$	10.556	1.167
$c(k) = \Gamma(1+2/k)/\Gamma(1+1/k)^2 - 1$	0.3666	
$c(k)\mu^2$ 对 $\mathrm{Var}[Y]$	$1.167 = 1.167$（碰巧相等）	

前两行是"模板不适用"的证据：密度能还原，但 b' 给出的是 $\mathbb{E}[Y^k]$ 而不是 $\mathbb{E}[Y]$。第三、四行说明：若只看方差，韦布尔**看起来**像 $V(\mu) = \mu^2$ 的家族，但这个对应关系不是由 $a(\phi)b''(\theta)$ 得来的。

怎么重算

在本目录下执行

```
python verify_edf.py
```

脚本做三件事：(1) 用 $(theta, \phi, a, b, c)$ 重建密度，与已知密度逐点比较（误差在 10^{-16} 量级）；(2) 数值核对 $b' = \mu$ 与 $ab'' = \mathrm{Var}$；(3) 打印上表的全部数字。脚本对韦布尔那一项特意标成"预期失败"——它失败，正是这一节的结论。

A　附录：六步法一页纸　Appendix: the six-step procedure on one page

这一页可以单独复印，放在讲台上。八个特例用的是同一套动作；忘记某一步时，回到这张纸。

六步

1. **写密度**（含支撑；先看支撑是否依赖参数）。
2. **取对数**（常数先不丢）。
3. **归并**：$\log f = y \cdot \kappa(\text{参数}) + A(y) + B(\text{参数})$。
4. **读** θ, b：$\theta = \kappa$；由 $B = -b(\theta)/a(\phi)$ 反解 b。
5. **读** $a(\phi), c(y;\phi)$：c 不含 θ。
6. **核对**：$b' = \mu$，$ab'' = \mathrm{Var}$；再求 $V(\mu) = b''(\theta(\mu))$ 与 $g(\mu) = \theta(\mu)$。

分布	θ	ϕ	$a(\phi)$	$b(\theta)$	$V(\mu)$	$g(\mu)$	符号
正态	μ	σ^2	ϕ	$\theta^2/2$	1	μ	$+$
伯努利	$\operatorname{logit}\pi$	1	1	$\log(1+e^\theta)$	$\mu(1-\mu)$	$\operatorname{logit}\mu$	$+$
二项	$\operatorname{logit}\pi$	1	1	$n\log(1+e^\theta)$	$\mu(1-\mu/n)$	$\log\frac{\mu}{n-\mu}$	$+$
泊松	$\log\mu$	1	1	e^θ	μ	$\log\mu$	$+$
指数	$-1/\mu$	1	1	$-\log(-\theta)$	μ^2	$-1/\mu$	$-$
伽马	$-1/\mu$	β	ϕ	$-\log(-\theta)$	μ^2	$-1/\mu$	$-$
逆高斯	$-1/(2\mu^2)$	$1/\lambda$	ϕ	$-\sqrt{-2\theta}$	μ^3	$-1/(2\mu^2)$	$-$

最后一列"符号"指 θ 的正负：$+$ 的家族 $\theta\in\mathbb{R}$（正态为全体实数，二项为 $\mathbb{R}$，泊松为 $\mathbb{R}$）；$-$ 的三个家族要求 $\theta<0$，这是它们 b 里出现 $-\log(-\theta)$ 或 $-\sqrt{-2\theta}$ 的原因。

B　附录：从得分方程到 IRLS　Appendix: score equation → IRLS

这一节不属于第 4 章的考试范围，但它是"为什么本章要花那么大力气讲 $V(\mu)$"的直接答案。讲完第 41 帧若还有三分钟，可以把它当预告。

第 1 步：写出对数似然（典则连接）

设 $\theta_i=\eta_i=\mathbf{x}_i^\top\boldsymbol{\beta}$，则

$$\ell(\boldsymbol{\beta})=\sum_{i=1}^{n}\frac{y_i\theta_i-b(\theta_i)}{a(\phi)}+\text{const.}$$

第 2 步：求得分与海森矩阵

$$\frac{\partial\ell}{\partial\boldsymbol{\beta}}=\sum_{i=1}^{n}\frac{y_i-b'(\theta_i)}{a(\phi)}\,\mathbf{x}_i=\frac{1}{a(\phi)}\mathbf{X}^\top(\mathbf{y}-\boldsymbol{\mu}),$$

$$\frac{\partial^2\ell}{\partial\boldsymbol{\beta}\,\partial\boldsymbol{\beta}^\top}=-\sum_{i=1}^{n}\frac{b''(\theta_i)}{a(\phi)}\,\mathbf{x}_i\mathbf{x}_i^\top=-\frac{1}{a(\phi)}\mathbf{X}^\top\mathbf{W}\mathbf{X},\qquad\mathbf{W}=\operatorname{diag}\big(V(\mu_i)\big).$$

第 3 步：Fisher scoring = 加权最小二乘

迭代

$$\boldsymbol{\beta}^{(t+1)}=\boldsymbol{\beta}^{(t)}+\big(\mathbf{X}^\top\mathbf{W}\mathbf{X}\big)^{-1}\mathbf{X}^\top(\mathbf{y}-\boldsymbol{\mu})=\big(\mathbf{X}^\top\mathbf{W}\mathbf{X}\big)^{-1}\mathbf{X}^\top\mathbf{W}\mathbf{z},$$

其中**工作响应**（working response）

$$z_i=\eta_i+\frac{y_i-\mu_i}{V(\mu_i)}.$$

$a(\phi)$ 在两边约掉，所以**拟合 $\boldsymbol{\beta}$ 不需要知道 ϕ**——这就是为什么本章说"分布只通过 V 与 g 进入算法"。

三个可以直接讲的观察

(1) 若 $V(\mu)\equiv1$（正态），$z_i=\eta_i+(y_i-\mu_i)=y_i$，IRLS 一步收敛到普通最小二乘。
(2) 若 $V(\mu)=\mu$（泊松），μ 大的观测权重 $1/\mu$ 小——与"计数越大越不可靠"的直觉一致。
(3) 若用非典则连接，海森矩阵里会多出一项（含 $\partial^2 g/\partial\mu^2$），Newton 与 Fisher scoring 不再相同；这时的"IRLS"只对期望信息成立。

下一章会把这个迭代展开成完整算法，并讨论收敛与初值。本章留下的唯一伏笔是：**估 β 用的是 $V(\mu)$，估 ϕ 用的是偏差**——两件事分开做，这也是 GLM 与正态线性模型在计算上最大的结构差别。